



MUST UNIVERSITY

MASTER OF SCIENCE IN BUSINESS ADMINISTRATION (DIGITAL MARKETING
CONCENTRATION)

EDUARDO CAMARGO MAIA

**O USO DO MARKETING DIGITAL POR MICRO, PEQUENAS E MÉDIAS
EMPRESAS (PMES) PÓS DIFUSÃO DE FERRAMENTAS DE INTELIGÊNCIA
ARTIFICIAL GENERATIVA: UM ESTUDO DE CASO COM PMES DO MUNICÍPIO
DE CAPIVARI-SP.**

FLORIDA – USA



JANEIRO/2026

EDUARDO CAMARGO MAIA

**O USO DO MARKETING DIGITAL POR MICRO, PEQUENAS E MÉDIAS
EMPRESAS (PMES) PÓS DIFUSÃO DE FERRAMENTAS DE INTELIGÊNCIA
ARTIFICIAL GENERATIVA: UM ESTUDO DE CASO COM PMES DO MUNICÍPIO
DE CAPIVARI-SP.**

Trabalho de Conclusão Final apresentado
como requisito parcial para obtenção do título
de Mestre no Curso de Master of Science In
Business Administration (Digital Marketing
Concentration) da MUST University –
Florida USA.

Orientador: Prof. Dr. Marcos Crivelaro



FLORIDA – USA

JANEIRO/2026

Lista de Figuras

Figura 01: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Figura 02: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Figura 03: XXXXXXXXXXXXXXXXXXXXXXXX.....	00



Lista de Quadros

Quadro 01: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Quadro 02: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Quadro 03: XXXXXXXXXXXXXXXXXXXXXXXX.....	00



Lista de Gráficos

Gráfico 01: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Gráfico 02: XXXXXXXXXXXXXXXXXXXXXXXX.....	00
Gráfico 03: XXXXXXXXXXXXXXXXXXXXXXXX.....	00



Lista de Abreviaturas e Siglas

APA – American Psychological Association

ABDI – Agência Brasileira de Desenvolvimento Industrial

AI – Artificial Intelligence (Inteligência Artificial)

BNDES - Banco Nacional de Desenvolvimento Econômico e Social

CRM – Customer Relationship Management (Gestão de Relacionamento com o Cliente)

DALL-E – DALL-E (ferramenta de geração de imagens por Inteligência Artificial)

DIEESE – Departamento Intersindical de Estatística e Estudos Socioeconômicos

EPP – Empresas de Pequeno Porte

FGV – Fundação Getúlio Vargas

GPT – Generative Pre-trained Transformer (Transformador Pré-treinado Generativo)

IA – Inteligência Artificial

IBGE – Instituto Brasileiro de Geografia e Estatística

IBM – International Business Machines

IJEER – International Journal of Entrepreneurial Behavior & Research



IMD – Institute for Management Development (Instituto para o Desenvolvimento da Gestão)

JSBED – Journal of Small Business and Enterprise Development

LGPD – Lei Geral de Proteção de Dados

ME – Microempresas

MEI – Microempreendedor Individual

MIS – Management Information Systems (Sistemas de Informação Gerencial)

MJSSH – Malaysian Journal of Social Sciences and Humanities

PME – Pequenas e Médias Empresas (plural: PMEs)

RBV – Resource-Based View (Visão Baseada em Recursos)

RPA – Robotic Process Automation (Automação Robótica de Processos)

SEBRAE – Serviço Brasileiro de Apoio às Micro e Pequenas Empresas

SME – Small and Medium-sized Enterprises (Pequenas e Médias Empresas)

SP – São Paulo

TAM – Technology Acceptance Model (Modelo de Aceitação de Tecnologia)

UTAUT – Unified Theory of Acceptance and Use of Technology (Teoria Unificada de Aceitação e Uso de Tecnologia)



Abstract

Keywords: lorem ipsum, lorem ipsum, lorem ipsum, lorem ipsum, lorem ipsum

SUMÁRIO

1 INTRODUÇÃO.....	12
1.1 Contextualização e Relevância do Tema.....	12
1.2 Problema de Pesquisa e Questões Norteadoras.....	14
1.3 Objetivos.....	20
1.3.1 Objetivo Geral.....	20
1.3.2 Objetivos Específicos.....	21
1.4 Justificativa.....	24
1.5 Estrutura do Trabalho.....	25
2 FUNDAMENTAÇÃO TEÓRICA.....	29
2.1 Marketing Digital: Conceitos, Evolução e Aplicações.....	29
2.1.1. Fundamentos Conceituais do Marketing Moderno.....	29
2.1.2. A Evolução do Marketing Tradicional ao Digital.....	32
2.1.3. Aplicações Contemporâneas do Marketing Digital.....	34
2.1.4. Marketing Digital no Contexto Brasileiro e das PMEs.....	36
2.1.5. A Inteligência Artificial como Nova Fronteira do Marketing Digital.....	38
2.1.6. Síntese - Marketing Digital.....	39
2.2 Micro, Pequenas e Médias Empresas (PMEs) e o Marketing Digital.....	40
2.2.1 Caracterização das PMEs no Contexto Brasileiro.....	40
2.2.1.1. Critérios de Classificação de PMEs no Brasil.....	41
2.2.1.3. Níveis de Maturidade Digital das PMEs: Análise Setorial e Regional.....	44
2.2.2 Desafios e Oportunidades do Marketing Digital para PMEs.....	48
2.2.2.1 Barreiras Estruturais à Adoção Digital: Uma Perspectiva Baseada em Fatores Críticos.....	49
2.2.2.2 Oportunidades Percebidas: Dimensões de Geração de Valor.....	50
2.2.2.3 A Realidade Empírica no Contexto das PMEs.....	50
2.2.2.4 Síntese e a Nova Fronteira Tecnológica.....	51
2.3 Inteligência artificial Aplicada ao Marketing.....	52

2.3.1 Conceitos e Tipologias de IA (IA Mecânica, de Pensamento e Sentimental).....	52
2.3.1.1 Um Framework Estratégico para a IA no Marketing: As Três Inteligências.	52
2.3.1.2 Contextualizando a Evolução: Da Automação de Processos à Era Generativa.....	53
2.3.1.3 Aprofundando as Dimensões da IA e suas Limitações.....	54
2.3.2 Aplicações de IA em Marketing Digital.....	55
2.3.2.1 Produto/Consumidor: Da Padronização à Personalização.....	56
2.3.2.2 Preço/Custo: Da Automação Transacional à Otimização Dinâmica.....	57
2.3.2.3 Praça/Conveniência: Da Automação Logística à Antecipação Preditiva.....	59
2.3.2.4 Promoção/Comunicação: Epicentro da Transformação Generativa.....	60
2.3.2.5 IA Generativa em PMEs.....	61
2.3.2.6 Síntese Conceitual.....	62
2.3.3 IA como recurso estratégico para PME's.....	62
2.3.3.1 Análise da IA como Recurso para PMEs sob a Ótica do VRIN.....	63
2.3.3.2 Validação Empírica em Economias em Desenvolvimento.....	65
2.3.3.3 Síntese e Transição para o Modelo de Aceitação.....	66
2.4 Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT).....	67
2.4.1 Construtos Centrais do UTAUT.....	68
2.4.2 Aplicações do UTAUT em Contextos de PMEs.....	70
2.5 Síntese da Fundamentação Teórica e Framework Conceitual.....	72
2.5.1 Modelo UTAUT como Base Estruturante.....	73
2.5.2 Integração com a Taxonomia das Três Inteligências (Huang & Rust, 2021).....	76
2.5.3 Integração com Taxonomia de Tarefas de IA (Davenport et al., 2020).....	78
2.5.4 Integração com Drivers e Barreiras de Adoção em PMEs.....	81
2.5.5 Framework Conceitual Integrado.....	84
2.5.6 Categorias de Análise Emergentes.....	88
2.5.6 Síntese do Framework conceitual.....	90
3 METODOLOGIA.....	92
3.1 Caracterização da Pesquisa.....	92
3.2 Estratégia de Pesquisa: Estudo de Caso Múltiplo.....	92
3.3 Definição da População e Critérios de Seleção.....	92
3.4 Instrumentos e Procedimentos de Coleta de Dados.....	92
3.5 Procedimentos de Análise de Dados.....	92
3.6 Aspectos Éticos da Pesquisa.....	92
4 APRESENTAÇÃO E ANÁLISE DOS RESULTADOS.....	92
4.1 Caracterização das Empresas Investigadas.....	92

4.2 Análise Temática conforme Objetivos Específicos.....	92
4.2.1 Práticas de Marketing Digital e Integração da IA.....	92
4.2.2 Impactos Percebidos da Adoção de IA.....	92
4.2.3 Fatores Determinantes para Adoção: Análise à Luz do UTAUT.....	92
4.3 Síntese dos Achados por Caso.....	92
5 DISCUSSÃO DOS RESULTADOS.....	93
5.1 Confronto dos Achados com a Literatura.....	93
5.2 Implicações Teóricas.....	93
5.3 Implicações Práticas e Gerenciais.....	93
6 CONCLUSÕES E RECOMENDAÇÕES.....	93
6.1 Conclusões em Relação aos Objetivos.....	93
6.2 Limitações do Estudo.....	93
6.3 Recomendações para Futuras Pesquisas.....	93
6.4 Recomendações para Gestores de PMEs.....	93
REFERÊNCIAS.....	93
GLOSSÁRIO.....	98
APÊNDICE.....	98

1 INTRODUÇÃO

1.1 Contextualização e Relevância do Tema

As Micro, Pequenas e Médias Empresas (PMEs) constituem a espinha dorsal da economia brasileira, representando aproximadamente 97,72% do total de estabelecimentos, 26,5% do Produto Interno Bruto (PIB) nacional e sendo responsáveis por quase metade (48,9%) dos empregos formais no país (Serviço Brasileiro de Apoio às Micro e Pequenas Empresas [SEBRAE] & Fundação Getúlio Vargas [FGV], 2024). Esses números evidenciam não apenas uma predominância quantitativa, mas sobretudo a centralidade dessas organizações na geração de renda, na promoção da inclusão social e na dinamização de economias locais e regionais. Este cenário de extrema relevância não se restringe ao Brasil. Em escala global, as PMEs correspondem a cerca de 90% dos negócios e são geradoras de mais de 50% dos empregos (Thaha et al., 2021), consolidando-se como agentes fundamentais para o desenvolvimento econômico sustentável em diversas nações.

Apesar de sua vital importância econômica, essas organizações enfrentam barreiras significativas para competir em um mercado progressivamente digitalizado. Relatórios de maturidade digital do SEBRAE (2023, 2024) apontam que a maioria das PMEs brasileiras ainda se encontra em estágios iniciais de adoção de tecnologias digitais, com lacunas críticas em capacitação, infraestrutura tecnológica e recursos financeiros destinados à transformação digital. A literatura acadêmica corrobora esse diagnóstico ao documentar que as PMEs historicamente enfrentam obstáculos estruturais à digitalização,

incluindo limitações de conhecimento técnico, escassez de capital humano especializado, restrições orçamentárias e dificuldades na mensuração do retorno sobre investimentos em tecnologias digitais (Taiminen & Karjaluoto, 2015). Esse conjunto de desafios configura o que pode ser caracterizado como uma lacuna persistente de maturidade digital, que compromete a capacidade competitiva dessas empresas frente a organizações de maior porte e maior grau de sofisticação tecnológica.

Enquanto a literatura prévia sobre marketing digital em PMEs documentou desafios estruturais persistentes, a difusão massiva de ferramentas de inteligência artificial generativa a partir de 2022, notadamente com o lançamento de modelos como o ChatGPT, representa uma ruptura tecnológica sem precedentes (Has & Knežević, 2024). Pela primeira vez, capacidades avançadas de IA tornaram-se amplamente acessíveis, de baixo custo e operáveis por usuários sem profundo conhecimento técnico. Se anteriormente a Inteligência Artificial nos negócios concentrava-se em aplicações de automação de processos, insight cognitivo e engajamento cognitivo, predominantemente em grandes corporações com recursos substanciais (Davenport & Ronanki, 2018), a nova geração de ferramentas baseadas em modelos de linguagem de grande escala democratizou o acesso a tecnologias antes restritas. Esta democratização tecnológica apresenta potencial para alterar fundamentalmente as dinâmicas competitivas, oferecendo às PMEs instrumentos anteriormente inacessíveis para criação de conteúdo, atendimento ao cliente, análise de dados e personalização de estratégias de marketing.

A convergência entre os desafios históricos das PMEs e o potencial disruptivo da IA acessível cria uma lacuna crítica e urgente na literatura acadêmica. Has & Knežević

(2024) corroboram essa urgência ao documentarem um crescimento exponencial de publicações sobre digitalização nas PMEs, sinalizando a emergência deste tema, mas ainda com escassa atenção empírica específica sobre a IA generativa neste contexto organizacional. Esta janela temporal singular — caracterizada pela rápida difusão tecnológica e pela reconfiguração das práticas de marketing digital — demanda investigação sistemática sobre como as PMEs estão efetivamente adotando, adaptando e integrando ferramentas de IA em suas estratégias de marketing. Compreender os fatores determinantes dessa adoção, os impactos nas operações cotidianas e as transformações nas práticas estabelecidas torna-se essencial tanto para o avanço teórico dos modelos de aceitação de tecnologia quanto para a formulação de recomendações práticas que subsidiem gestores de PMEs em suas decisões estratégicas de transformação digital.

1.2 Problema de Pesquisa e Questões Norteadoras

O cenário delineado — PMEs economicamente vitais, historicamente limitadas em sua digitalização, agora diante de ferramentas de IA generativa democratizadas — configura um fenômeno cuja manifestação empírica permanece inexplorada. A literatura acadêmica construiu, nas últimas duas décadas, *frameworks* robustos sobre o potencial transformador da Inteligência Artificial no marketing (Huang & Rust, 2021; Davenport et al., 2020), documentando aplicações que vão desde a automação de processos até a personalização em larga escala e a análise preditiva de comportamento do consumidor. Paralelamente, estudos sobre marketing digital em PMEs consolidaram diagnósticos sobre os desafios estruturais persistentes anteriormente citados — limitações de conhecimento técnico, escassez de recursos financeiros e humanos, dificuldades de mensuração de resultados — que restringem

a capacidade competitiva desses negócios (Taiminen & Karjaluoto, 2015). Contudo, essas duas correntes de pesquisa permaneceram essencialmente desconectadas: os estudos sobre IA concentram-se em grandes corporações e contextos de países desenvolvidos, enquanto a literatura sobre PMEs antecede a difusão massiva de ferramentas generativas pós-2022.

Essa desconexão configura uma lacuna crítica e multidimensional na literatura. Davenport et al. (2020), em sua agenda de pesquisa sobre IA e marketing publicada no *Journal of the Academy of Marketing Science*, reconhecem explicitamente a ausência de estudos empíricos sobre adoção de IA em diferentes tipos de organizações, particularmente em PMEs. Thaha et al. (2021), em revisão sistemática sobre marketing digital em pequenas empresas, identificam necessidade urgente de investigações em contextos geográficos específicos de países em desenvolvimento e sobre ferramentas digitais além das mídias sociais tradicionais — precisamente o território onde a IA generativa opera. Mais recentemente, Has & Knežević (2024), ao mapearem tendências de pesquisa sobre digitalização de PMEs, propõem 16 questões de pesquisa futuras focadas em ferramentas emergentes e contextos pós-COVID, mas documentam que a IA generativa não aparece como trending topic em suas análises bibliométricas até 2022, evidenciando a janela temporal que este estudo pretende capturar. A convergência dessas lacunas explicitadas — ausência de foco em PMEs (Davenport et al., 2020), necessidade de estudos em contextos de países em desenvolvimento (Thaha et al., 2021) e gap temporal sobre ferramentas generativas (Has & Knežević, 2024) — demonstra inequivocamente a relevância e urgência da presente investigação.

Diante dessa lacuna multidimensional, o presente estudo orienta-se pelo seguinte problema de pesquisa:

De que maneira a adoção e o uso de ferramentas de Inteligência Artificial reconfiguram as práticas, estratégias e desafios no Marketing Digital de Micro, Pequenas e Médias Empresas (PMEs)?

O termo "reconfigurar" é aqui empregado deliberadamente para capturar não apenas a implementação técnica de novas ferramentas, mas as transformações substantivas nas rotinas organizacionais, nos processos decisórios e nas estratégias competitivas das PMEs. Trata-se de investigar se — e como — a IA está alterando a natureza das atividades de marketing digital, os recursos mobilizados, as competências exigidas e os resultados alcançados. A ênfase em "práticas, estratégias e desafios" reflete uma abordagem multidimensional que reconhece a complexidade do fenômeno: práticas referem-se às ações cotidianas e operacionais; estratégias dizem respeito às decisões de longo prazo e ao posicionamento competitivo; e desafios englobam tanto os obstáculos enfrentados quanto as barreiras superadas ou persistentes. Esta tríplice dimensão permite uma compreensão abrangente que transcende análises meramente descritivas de adoção tecnológica, adentrando o território das implicações organizacionais e gerenciais.

Para operacionalizar a investigação deste problema, o estudo orienta-se pelas seguintes questões norteadoras:

QN1. Quais são as ferramentas e táticas atuais de Marketing Digital adotadas pelas PMEs investigadas, e como a Inteligência Artificial tem sido integrada ou sobreposta a essas práticas estabelecidas?

QN2. De que forma a Inteligência Artificial é percebida e utilizada pelos gestores para otimizar ou transformar tarefas específicas (ex.: criação de conteúdo, atendimento ao cliente, análise de dados, segmentação de público) dentro do escopo do Marketing Digital da PME?

QN3. Na percepção dos gestores, quais são as principais mudanças (benefícios, desafios e limitações) que a adoção da IA tem gerado na rotina operacional, nos processos decisórios e nos resultados estratégicos das campanhas de Marketing Digital?

QN4. De que maneira a Inteligência Artificial é vista pelos gestores como um recurso para mitigar obstáculos tradicionais do Marketing Digital em PMEs, tais como restrições orçamentárias, escassez de mão de obra especializada e limitações de tempo?

QN5. Como as PMEs que ainda não adotaram ferramentas de IA percebem as barreiras para adoção, e quais são as principais diferenças de percepção entre gestores adotantes e não-adotantes?

QN6. Que fatores são apontados pelos gestores como mais decisivos na intenção e na efetiva adoção de ferramentas de IA para o Marketing Digital, considerando: (a) as expectativas de melhoria de desempenho (ganhos percebidos); (b) a facilidade de uso percebida (complexidade técnica); (c) a influência de stakeholders externos (fornecedores,

concorrentes, clientes); (d) as condições organizacionais facilitadoras (recursos financeiros, infraestrutura tecnológica, capacitação da equipe)?

Estas questões estabelecem uma progressão lógica que parte da caracterização das práticas atuais (QN1), passa pela compreensão dos usos e percepções específicas (QN2, QN3), investiga o papel mitigador da IA frente aos desafios históricos das PMEs (QN4), contrasta perspectivas de adotantes e não-adotantes (QN5) e culmina na identificação dos fatores determinantes de adoção (QN6). Essa arquitetura investigativa assegura que o fenômeno seja examinado em suas múltiplas facetas, desde a dimensão operacional até os determinantes comportamentais da aceitação tecnológica.

Do ponto de vista conceitual, é fundamental delimitar com precisão o escopo da investigação. Por "ferramentas de Inteligência Artificial", este estudo refere-se especificamente às tecnologias baseadas em **IA generativa** que se tornaram amplamente acessíveis a partir de 2022, tais como modelos de linguagem de grande escala (LLMs Americanas como ChatGPT, Google Gemini, Claude e LLMs Chinesas tais como: Qwen, GLM e Deepseek), geradores de imagens (Nano Banana, DALL-E, Midjourney, Stable Diffusion), ferramentas de edição de vídeo assistidas por IA e plataformas de automação de marketing que incorporam recursos generativos. Esta delimitação justifica-se por três razões: primeiro, essas ferramentas representam uma ruptura qualitativa em relação às gerações anteriores de IA, caracterizando-se pela capacidade de criar conteúdo original, pela interface intuitiva e pelo baixo custo de acesso; segundo, são precisamente essas tecnologias que se tornaram disponíveis às PMEs sem exigir investimentos elevados ou conhecimento técnico especializado; terceiro, a literatura acadêmica ainda não documentou sistematicamente como

essas ferramentas específicas estão sendo apropriadas por pequenos negócios no contexto brasileiro. O foco recai, portanto, não sobre sistemas complexos de IA empresarial (*enterprise AI*) ou soluções customizadas de alto custo, mas sobre ferramentas democratizadas que qualquer gestor de PME pode acessar com recursos limitados.

A ancoragem teórica do estudo no Modelo Unificado de Aceitação e Uso de Tecnologia — UTAUT (Venkatesh et al., 2003) justifica-se por sua robustez empírica comprovada em múltiplos contextos organizacionais e por sua capacidade de integrar construtos de teorias predecessoras (TAM entre outras) em um *framework* coeso e controlado. O UTAUT permite investigar sistematicamente os determinantes da intenção comportamental e do uso efetivo de tecnologias, considerando variáveis moderadoras como gênero, idade, experiência e voluntariedade de uso. No contexto das PMEs brasileiras, a aplicação deste modelo à adoção de IA generativa oferece potencial para testar sua validade externa em um cenário até então não explorado — pequenas empresas de países em desenvolvimento enfrentando tecnologias radicalmente novas — e para identificar eventuais construtos emergentes específicos deste contexto, tais como limitações de recursos financeiros, capacidade absorviva reduzida ou percepções sobre riscos competitivos.

A investigação deste problema contribui teoricamente para a literatura de Administração e Marketing ao fornecer evidências empíricas qualitativas que preenchem simultaneamente as lacunas identificadas por Davenport et al. (2020), Thaha et al. (2021) e Has & Knežević (2024): oferece dados sobre adoção de IA em PMEs, em contexto geográfico de país em desenvolvimento, focando em ferramentas generativas emergentes

pós-2022. Ao testar e potencialmente estender o modelo UTAUT nesse cenário inédito, o estudo contribui para o refinamento de teorias de aceitação de tecnologia.

Os achados deste trabalho podem subsidiar gestores de PMEs na tomada de decisões mais informadas sobre investimento e integração de IA no Marketing Digital, considerando que essas organizações operam com recursos financeiros e humanos escassos. Ademais, os resultados poderão orientar políticas públicas e programas de capacitação de instituições de apoio às PMEs, fornecendo um diagnóstico baseado em evidências sobre barreiras, facilitadores e melhores práticas de adoção de IA no marketing digital.

1.3 Objetivos

Para investigar sistematicamente o problema de pesquisa apresentado, este estudo estabelece um objetivo geral que expressa seu propósito central e três objetivos específicos que operacionalizam a investigação empírica. Esses objetivos foram construídos em alinhamento direto com as questões norteadoras, assegurando coerência metodológica entre o problema identificado, as perguntas formuladas e as metas investigativas estabelecidas.

1.3.1 Objetivo Geral

Analisar, sob a perspectiva de gestores, como a adoção e o uso de ferramentas de Inteligência Artificial (IA) reconfiguram as práticas, estratégias e desafios de Marketing Digital em Micro, Pequenas e Médias Empresas (PMEs) no município de Capivari-SP.

Este objetivo expressa o compromisso central da pesquisa em ir além de uma descrição superficial da presença de ferramentas de IA nas PMEs. O verbo "analisar" indica a intenção de examinar criticamente as relações causais, os mecanismos subjacentes e as implicações multidimensionais do fenômeno. A explicitação "sob a perspectiva de gestores" ancora a investigação na abordagem qualitativa interpretativa, reconhecendo que as percepções, experiências e narrativas dos decisores constituem o núcleo da compreensão pretendida. O termo "reconfigurar" mantém o foco nas transformações substantivas — não apenas na adoção tecnológica em si, mas em como essa adoção altera práticas estabelecidas, reformula estratégias competitivas e modifica a natureza dos desafios enfrentados.

1.3.2 Objetivos Específicos

Para operacionalizar o objetivo geral, foram estabelecidos três objetivos específicos que, em conjunto, cobrem as dimensões descritiva, perceptiva e explicativa do fenômeno:

- ❖ **OE1.** Identificar as práticas e ferramentas de Marketing Digital estabelecidas nas PMEs investigadas antes e após a difusão da IA generativa, caracterizando como a Inteligência Artificial está sendo integrada em tarefas específicas (criação de conteúdo, atendimento ao cliente, análise de dados, segmentação de público).
- ❖ **OE2.** Analisar, sob a ótica dos gestores, os impactos percebidos da adoção de IA nas operações e processos decisórios de Marketing Digital, identificando benefícios, desafios, limitações enfrentadas e o papel da tecnologia na mitigação de obstáculos tradicionais das PMEs (restrições orçamentárias, escassez de mão de obra especializada, limitações de tempo).

- ❖ **OE3.** Identificar e analisar, à luz do Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT) de Venkatesh et al. (2003), os fatores determinantes da intenção e do comportamento de adoção de ferramentas de IA para Marketing Digital, considerando as percepções de gestores adotantes e não-adotantes e a eventual emergência de constructos específicos do contexto de PMEs.

Esses três objetivos específicos seguem uma progressão lógica que estrutura a investigação empírica. O OE1 estabelece a dimensão descritiva da pesquisa, mapeando o estado atual das práticas de marketing digital e identificando onde e como a IA está sendo integrada. Esse objetivo fornece o contexto necessário para compreender as transformações em curso. O OE2 avança para a dimensão perceptiva e analítica, investigando como os gestores experimentam e interpretam os impactos da IA em suas operações cotidianas e decisões estratégicas, incluindo sua capacidade de mitigar desafios históricos das PMEs. O OE3 alcança a dimensão explicativa, buscando compreender os fatores que determinam por que alguns gestores adotam ferramentas de IA enquanto outros não, ancorado em um *framework* teórico consolidado que permite sistematizar os achados e gerar insights teóricos. Essa sequência — descrever, compreender impactos, explicar determinantes — assegura que a investigação capture tanto a fenomenologia da adoção quanto seus mecanismos subjacentes.

A Tabela 1 apresenta o alinhamento estrutural entre os objetivos específicos e as questões norteadoras que os operacionalizam, evidenciando a coerência interna do desenho de pesquisa:

Tabela 1

Alinhamento entre Objetivos Específicos e Questões Norteadoras

Objetivo específico	Questões norteadoras correspondentes	Dimensão investigativa
OE1 – Identificar práticas de Marketing Digital e integração da IA	QN1: Ferramentas e táticas atuais; integração da IA QN2: Percepção e utilização em tarefas específicas	Descritiva
OE2 – Analisar impactos percebidos da adoção de IA	QN3: Mudanças na rotina operacional e resultados QN4: IA como mitigadora de obstáculos tradicionais QN5: Percepção de barreiras (adotantes vs. não-adotantes)	Perceptiva/Analítica
OE3 – Identificar fatores determinantes (UTAUT)	QN6: Fatores decisivos para adoção (expectativas de desempenho, facilidade, influência social, condições facilitadoras)	Explicativa

Nota. OE = objetivo específico; QN = questão norteadora; UTAUT = Modelo Unificado de Aceitação e Uso de Tecnologia

Essa correspondência direta entre objetivos e questões norteadoras assegura que cada objetivo específico seja investigado por meio de perguntas empiricamente respondíveis nas entrevistas semiestruturadas. Mais importante, os três objetivos específicos, quando

alcançados de forma integrada, permitem responder de maneira abrangente ao problema de pesquisa e ao objetivo geral: compreender de que maneira (OE1), com quais impactos (OE2) e por que razões (OE3) a IA está reconfigurando o marketing digital de PMEs. Essa estrutura tripartite garante que a pesquisa não se limite a um mapeamento descritivo, mas avance em direção à compreensão profunda e teoricamente fundamentada do fenômeno.

Os objetivos aqui estabelecidos orientarão todas as etapas subsequentes da pesquisa. O desenho metodológico apresentado no Capítulo 3 foi estruturado especificamente para operacionalizar esses objetivos, com roteiro de entrevistas organizado em blocos temáticos correspondentes a cada objetivo específico e protocolo de análise de conteúdo desenhado para identificar categorias analíticas alinhadas a essas metas investigativas. A seção seguinte (1.4) aprofunda a justificativa para esta investigação, explicitando suas contribuições teóricas e práticas.

1.4 Justificativa

A urgência desta investigação fundamenta-se em sua natureza temporalmente situada. O fenômeno da adoção de IA generativa por PMEs encontra-se em estágio inicial de difusão, caracterizado por experimentação ativa, rápida evolução de ferramentas e formação de percepções primárias pelos gestores. Este é um momento crítico para a captura empírica: práticas ainda não se cristalizaram, percepções permanecem em construção e a memória das condições pré-IA está recente. Investigações realizadas em fases posteriores do ciclo de adoção — quando rotinas já estiverem estabelecidas e normalizadas — perderão a oportunidade de documentar o processo de reconfiguração em si, capturando apenas seus

resultados. A janela de oportunidade para estudar o "como" da transformação, e não apenas o "depois", é estreita e demanda ação investigativa imediata.

Esta pesquisa é relevante para múltiplos públicos. Gestores de PMEs beneficiam-se de um diagnóstico baseado em evidências sobre aplicações bem-sucedidas, barreiras concretas e fatores facilitadores, permitindo decisões mais informadas em contexto de recursos escassos. A comunidade acadêmica recebe dados empíricos que testam e potencialmente refinam teorias de aceitação de tecnologia em contextos sub-representados. Formuladores de políticas públicas e instituições de apoio como o SEBRAE obtêm subsídios para programas de capacitação e fomento à transformação digital alinhados às necessidades reais das PMEs brasileiras. Consultorias e desenvolvedores de tecnologia acessam insights sobre expectativas, dificuldades e requisitos específicos desse segmento de mercado. A delimitação geográfica em Capivari-SP, município representativo do interior brasileiro, oferece ainda potencial de replicação metodológica para estudos em contextos similares, ampliando o alcance dos achados.

O Capítulo 2 apresenta a fundamentação teórica que ancora esta investigação, revisando criticamente a literatura sobre marketing digital, PMEs, aplicações de IA e modelos de aceitação de tecnologia.

1.5 Estrutura do Trabalho

Este capstone está organizado em seis capítulos que seguem uma progressão lógica de construção do conhecimento científico: da contextualização do fenômeno à fundamentação teórica, da operacionalização metodológica à apresentação de achados empíricos, da

interpretação teoricamente fundamentada às conclusões e recomendações. Cada capítulo cumpre função específica no encadeamento argumentativo, assegurando que o problema de pesquisa seja respondido de forma sistemática, rigorosa e teoricamente ancorada. A estrutura reflete o alinhamento entre problema de pesquisa, objetivos, metodologia e análise, princípio fundamental da coerência interna em pesquisas qualitativas.

O Capítulo 2 – Fundamentação Teórica estabelece as bases conceituais e teóricas que ancoram a investigação. Organizado em quatro eixos conceituais, o capítulo inicia com a revisão de conceitos, evolução e aplicações do Marketing Digital, fornecendo a base necessária para compreender o campo de atuação das PMEs. Em seguida, examina especificamente as Micro, Pequenas e Médias Empresas no contexto brasileiro, documentando suas características estruturais, desafios históricos de digitalização e oportunidades abertas pelas tecnologias emergentes. O terceiro eixo aprofunda a Inteligência Artificial aplicada ao marketing, revisando tipologias de IA e suas aplicações em contextos de recursos limitados. Por fim, apresenta o Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT), detalhando seus construtos centrais e aplicações em contextos de PMEs. Esta fundamentação fornece as lentes teóricas necessárias para interpretar os achados empíricos apresentados nos capítulos subsequentes, estabelecendo categorias analíticas que orientarão a análise de conteúdo.

O Capítulo 3 – Metodologia descreve detalhadamente os procedimentos adotados para operacionalizar os objetivos de pesquisa, demonstrando rigor metodológico e possibilitando replicabilidade. O capítulo caracteriza a pesquisa quanto à sua natureza (aplicada), abordagem (qualitativa) e objetivos (exploratório-descritiva), justificando a estratégia de

estudo de caso múltiplo como apropriada para investigar o fenômeno em profundidade. Apresenta os critérios de seleção das PMEs participantes, enfatizando a busca por diversidade setorial e de estágios de adoção de IA. Detalha os instrumentos de coleta de dados (entrevistas semiestruturadas) e os procedimentos de análise (Análise de Conteúdo segundo Bardin), explicitando como cada objetivo específico será operacionalizado empiricamente. Por fim, aborda os aspectos éticos da pesquisa, incluindo os protocolos de consentimento e garantias de anonimato. Este capítulo estabelece a ponte entre o *framework* teórico e a investigação empírica.

O Capítulo 4 – Apresentação e Análise dos Resultados constitui o núcleo empírico do trabalho, apresentando de forma sistemática os achados obtidos nas entrevistas com gestores das PMEs investigadas. O capítulo inicia com a caracterização detalhada das empresas participantes, contextualizando seus perfis setoriais, porte, histórico de digitalização e estágio de adoção de IA. Em seguida, organiza a análise em três blocos temáticos alinhados aos objetivos específicos: (i) identificação das práticas de Marketing Digital estabelecidas e formas de integração da IA; (ii) análise dos impactos percebidos pelos gestores nas operações e processos decisórios; (iii) identificação dos fatores determinantes da adoção à luz dos construtos do UTAUT. Cada bloco apresenta categorias analíticas emergentes da Análise de Conteúdo, ilustradas com excertos representativos das entrevistas que evidenciam padrões, divergências e nuances nas percepções dos gestores. O capítulo encerra com síntese dos achados por caso, permitindo visualização comparativa entre as empresas investigadas. Esta apresentação estruturada dos dados constitui a base empírica sobre a qual a discussão teórica será construída.

O Capítulo 5 – Discussão dos Resultados representa o momento de síntese intelectual do trabalho, confrontando os achados empíricos com a literatura revisada e gerando insights teóricos e práticos. Organizado em três seções, o capítulo inicia confrontando sistematicamente os resultados obtidos com os estudos revisados no Capítulo 2, identificando convergências, divergências e achados inesperados. Esta triangulação entre dados empíricos e literatura permite avaliar em que medida os resultados confirmam, refinam ou desafiam teorias estabelecidas. A segunda seção explicita as implicações teóricas, discutindo como os achados contribuem para o avanço do conhecimento sobre adoção de tecnologia em PMEs, potenciais extensões do modelo UTAUT e constructos emergentes específicos do contexto investigado. A terceira seção apresenta implicações práticas e gerenciais, traduzindo os achados em recomendações acionáveis para gestores de PMEs, formuladores de políticas públicas e desenvolvedores de soluções tecnológicas. Este capítulo transforma dados brutos em conhecimento teoricamente fundamentado e praticamente relevante, cumprindo o compromisso do capstone com dupla contribuição — acadêmica e aplicada.

O Capítulo 6 – Conclusões e Recomendações retorna ao problema de pesquisa inicial, agora munido de evidências empíricas e interpretações teoricamente fundamentadas. O capítulo inicia apresentando as conclusões em relação a cada objetivo específico, demonstrando como os achados respondem às questões norteadoras formuladas. Em seguida, reconhece as limitações do estudo — delimitação geográfica, recorte temporal, natureza qualitativa — contextualizando o alcance das conclusões. A seção de recomendações para pesquisas futuras propõe uma agenda investigativa que inclui estudos longitudinais, comparações inter-regionais, abordagens quantitativas complementares e investigações sobre

ferramentas emergentes de IA. Por fim, apresenta recomendações práticas para gestores de PMEs, sintetizando aprendizados-chave sobre adoção bem-sucedida de IA no Marketing Digital. Este capítulo final fecha o círculo argumentativo iniciado no Capítulo 1, oferecendo respostas fundamentadas ao problema de pesquisa e apontando caminhos para avanço contínuo do conhecimento.

A estrutura adotada assegura progressão lógica e cumulativa: cada capítulo constrói sobre os anteriores, preparando o terreno para os subsequentes. O movimento do trabalho parte de uma pergunta (Cap. 1), ancora-se em teoria (Cap. 2), define procedimentos rigorosos (Cap. 3), apresenta evidências (Cap. 4), interpreta achados (Cap. 5) e oferece conclusões fundamentadas (Cap. 6). Esta arquitetura argumentativa garante que o capstone não apenas descreva um fenômeno, mas o compreenda profundamente, contribuindo tanto para o avanço teórico quanto para a prática gerencial em PMEs brasileiras.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Marketing Digital: Conceitos, Evolução e Aplicações

A compreensão do marketing digital como campo de conhecimento e prática organizacional demanda, primeiramente, o entendimento de suas raízes conceituais no marketing tradicional. Esta seção estabelece os alicerces teóricos necessários para a posterior análise de como as Micro, Pequenas e Médias Empresas (PMEs) brasileiras integram ferramentas digitais, especialmente aquelas baseadas em Inteligência Artificial, em suas estratégias mercadológicas. Percorre-se, assim, uma trajetória que parte dos fundamentos do

marketing moderno, atravessa sua transformação digital e culmina nas aplicações contemporâneas que caracterizam o cenário competitivo atual.

2.1.1. Fundamentos Conceituais do Marketing Moderno

O marketing, enquanto disciplina científica e prática gerencial, consolidou-se ao longo do século XX como elemento central na gestão empresarial. Segundo Kotler, Kartajaya e Setiawan (2024/2025, pp. 14-15), "uma das principais funções do marketing é comunicar valor, fortalecendo a confiança do cliente e permitindo que a marca influencie comportamentos". No contexto contemporâneo, essa comunicação de valor é crescentemente mediada por tecnologias digitais, especialmente ferramentas baseadas em Inteligência Artificial, que permitem personalização em escala, automação de processos e análise preditiva de comportamento do consumidor (Davenport et al., 2020; Huang & Rust, 2021).

A abordagem kotleriana do marketing transcende a visão reducionista que o equipara meramente à propaganda ou às vendas, situando-o como filosofia organizacional centrada no mercado. Nesta perspectiva, compreender profundamente o público-alvo antes de qualquer ação mercadológica constitui condição essencial para estratégias bem-sucedidas (Gabriel & Kiso, 2023). Esta premissa adquire relevância ainda maior no contexto digital, onde a velocidade de mudança no comportamento do consumidor exige adaptações constantes nas estratégias de marketing.

O arcabouço teórico do marketing moderno encontra expressão operacional no conceito de composto de marketing, também denominado mix de marketing. Introduzido por McCarthy em 1960, o modelo dos 4Ps — Produto, Preço, Praça (distribuição) e Promoção —

representa uma das contribuições mais duradouras para a gestão mercadológica, fornecendo estrutura analítica que permite às organizações planejar e implementar ações voltadas para atender demandas do mercado de maneira eficiente (McCarthy, 1960, em Amaral, 2000).

O primeiro elemento, Produto, refere-se a tudo que pode ser oferecido ao mercado para satisfazer necessidades ou desejos dos consumidores. Kotler, Keller e Chernev (2024) propõem compreensão sofisticada deste elemento ao identificar três níveis constitutivos: o núcleo, que representa o benefício central; o produto básico, que engloba atributos tangíveis como design, marca e qualidade; e o produto ampliado, que abrange serviços adicionais como garantia, suporte pós-venda e instalação. Esta estratificação permite às empresas agregar valor às suas ofertas, diferenciando-se da concorrência e aumentando a percepção de valor pelo cliente — aspecto que ganha novas dimensões no ambiente digital, onde produtos e serviços frequentemente incorporam componentes tecnológicos e experiências online.

O segundo P, Preço, transcende a simples quantia monetária, refletindo a percepção de valor do consumidor e sendo influenciado por múltiplos fatores como custos de produção, concorrência e elasticidade da demanda. Kotler, Keller e Chernev (2024) destacam característica distintiva deste elemento: trata-se do único componente do composto que gera receita diretamente, enquanto os demais geram custos. Consequentemente, decisões de precificação devem equilibrar estrategicamente a lucratividade empresarial com a acessibilidade ao consumidor, garantindo competitividade mercadológica. No contexto digital, estratégias de precificação dinâmica, algoritmos de otimização de preços e modelos de negócio baseados em assinatura ou freemium ilustram a evolução deste elemento.

A Praça, terceiro elemento, refere-se ao conjunto de atividades que asseguram a entrega do produto ao consumidor final no local e momento adequados. Este componente engloba decisões relacionadas a canais de distribuição, logística, armazenamento e transporte. A eficiência na gestão da praça mostra-se fundamental para assegurar a disponibilidade do produto e criar experiência positiva para o cliente, aumentando a fidelidade e satisfação do consumidor. A transformação digital revolucionou este elemento, com e-commerce, marketplaces, omnicanalidade e logística inteligente reconfigurando completamente os canais de distribuição.

O quarto P, Promoção, responsabiliza-se por comunicar o valor do produto aos consumidores. Incorpora conjunto diversificado de ferramentas: propaganda, promoção de vendas, marketing direto, relações públicas e vendas pessoais. O objetivo da promoção consiste em informar, persuadir e lembrar os consumidores sobre os produtos, criando engajamento e estimulando decisões de compra. Kotler, Keller e Chernev (2024) enfatizam que a promoção deve ser planejada de forma integrada, utilizando diferentes canais de comunicação para alcançar o público-alvo de maneira eficiente e consistente. Este elemento sofreu transformação radical com a digitalização, multiplicando exponencialmente os canais e formatos comunicacionais disponíveis.

Embora o modelo dos 4Ps tenha sido concebido em contexto pré-digital, sua relevância perdura. A compreensão deste *framework* clássico mostra-se essencial, pois o marketing digital não o substitui, mas o estende e adapta às possibilidades tecnológicas contemporâneas.

2.1.2. A Evolução do Marketing Tradicional ao Digital

A transição do marketing tradicional para o marketing digital representa uma das transformações mais significativas na disciplina, impulsionada pelo crescimento exponencial da internet e das tecnologias digitais a partir da década de 1990. Esta evolução não constituiu mera adição de novos canais comunicacionais, mas reconfigurou fundamentalmente a natureza da relação entre empresas e consumidores, alterando dinâmicas de poder, fluxos informacionais e processos de criação de valor.

O marketing digital emerge como conjunto de estratégias focadas na oferta de marca ou organização no ambiente internet, diferenciando-se do marketing tradicional pelo uso de diversos canais online e métodos que facilitam a análise de resultados em tempo real (Kotler, Keller, & Chernev, 2024).

Gabriel e Kiso (2023) complementam estas definições ao destacar que o comportamento do público-alvo constitui o centro de qualquer ação de marketing e que conhecê-lo representa condição essencial para estratégias de sucesso. Quando o comportamento do público-alvo muda — como ocorreu massivamente com a adoção de tecnologias digitais — as estratégias de marketing necessariamente devem mudar. Esta observação captura elemento fundamental da transformação digital no marketing: não se trata apenas de utilizar novas ferramentas, mas de compreender e adaptar-se a novos padrões de comportamento do consumidor digital.

A evolução para o ambiente digital trouxe mudanças paradigmáticas em múltiplas dimensões. Primeiramente, alterou-se radicalmente o modelo comunicacional. No marketing

tradicional, predominava comunicação unidirecional, com empresas transmitindo mensagens para audiências relativamente passivas através de mídias de massa. O ambiente digital, por sua vez, possibilita comunicação muitos-para-muitos devido ao alto nível de conectividade, caracterizando-se por interatividade, bidirecionalidade e capacidade de resposta em tempo real (Baines et al., 2013, em Thaha et al., 2021).

Kotler, Kartajaya e Setiawan (2025) observam que as mídias sociais redefiniram o modo como as pessoas interagem entre si, permitindo que desenvolvam relacionamentos sem barreiras geográficas e demográficas. Este fenômeno não apenas expandiu o alcance potencial das ações de marketing, mas também transferiu poder significativo para os consumidores, que passaram a produzir conteúdo, avaliar produtos e serviços publicamente e influenciar decisões de compra de outros consumidores através do marketing boca-a-boca digital.

Kotler, Kartajaya e Setiawan (2025) propõem periodização da evolução do marketing que ilustra esta transição. O Marketing 1.0 focava no produto; o Marketing 2.0 orientava-se para o consumidor; o Marketing 3.0 incorporava valores humanos; e o Marketing 4.0, subtítulo "do tradicional ao digital", reconhece a convergência entre marketing offline e online. Esta última fase caracteriza-se pela coexistência e integração de abordagens tradicionais e digitais, com empresas necessitando dominar ambos os domínios para alcançar efetividade mercadológica.

A transformação digital no marketing não se limitou aos canais comunicacionais, estendendo-se aos processos de segmentação, posicionamento e personalização. Capacidades

analíticas proporcionadas por big data e algoritmos de aprendizado de máquina permitem segmentação extremamente granular e personalização em escala — paradoxo que o marketing tradicional não poderia resolver. Como destacam Kotler, Kartajaya e Setiawan (2025), estas tecnologias possibilitam personalizar experiências, resolver problemas complexos e contribuir para desenvolvimento sustentável e inclusão social.

2.1.3. Aplicações Contemporâneas do Marketing Digital

As aplicações contemporâneas do marketing digital manifestam-se através de diversidade de táticas, canais e ferramentas que, em conjunto, formam ecossistema complexo e em constante evolução. Torres (2009) propõe que o marketing digital seja compreendido através de sete ações estratégicas principais: marketing de conteúdo, marketing nas mídias sociais, marketing viral, e-mail marketing, publicidade online, pesquisa online e monitoramento. Esta taxonomia, embora não exaustiva, captura as principais modalidades de atuação no ambiente digital.

O marketing de conteúdo refere-se à criação e distribuição de conteúdo valioso, relevante e consistente para atrair e engajar audiência claramente definida. Diferentemente da publicidade tradicional, que interrompe, o marketing de conteúdo busca informar, educar ou entreter, estabelecendo relação de valor com potenciais clientes antes mesmo da transação comercial. Esta abordagem alinha-se ao que Godin (1999) denominou "marketing de permissão", em contraste com o "marketing de interrupção" característico das mídias tradicionais.

As mídias sociais constituem elemento central do marketing digital contemporâneo. Plataformas como Facebook, Instagram, LinkedIn, Twitter e TikTok transformaram-se em espaços onde empresas estabelecem presença, engajam audiências e constroem relacionamentos com clientes. Kotler, Kartajaya e Setiawan (2025) enfatizam que estas plataformas criaram ambiente onde interação direta tornou-se não apenas viável, mas essencial, permitindo que marcas ouçam feedback em tempo real e ajustem estratégias e produtos com maior precisão. Além disso, as redes sociais funcionam como canais valiosos para coleta de feedback em tempo real, permitindo que empresas compreendam melhor expectativas e percepções dos clientes.

Pesquisa do SEBRAE (2023, 2024) sobre maturidade digital de PMEs brasileiras revela que o uso de mídias sociais para conectar e engajar clientes constitui uma das boas práticas digitais mais difundidas, embora ainda enfrente desafios de profissionalização. Os dados indicam evolução positiva ao longo dos anos, com crescente reconhecimento da importância estratégica destes canais.

O e-mail marketing, embora seja uma das formas mais antigas de marketing digital, permanece relevante devido a sua efetividade em termos de retorno sobre investimento e capacidade de personalização. Permite comunicação direta, segmentada e mensurável com clientes e potenciais clientes. Quando integrado a sistemas de CRM (*Customer Relationship Management*) e automação de marketing, possibilita jornadas de cliente sofisticadas e altamente personalizadas.



Otimização para mecanismos de busca (SEO) e marketing em mecanismos de busca (SEM) representam aplicações fundamentais do marketing digital. (Gabriel & Kiso, 2023) dedica atenção significativa a estas práticas, reconhecendo que presença nos resultados de busca constitui fator crítico para a visibilidade online. A lógica subjacente é simples: se consumidores cada vez mais iniciam processos de compra através de buscas online, aparecer de forma proeminente nos resultados torna-se imperativo estratégico.

A publicidade online, através de formatos como display ads, search ads, social ads e vídeo ads, oferece vantagens significativas sobre publicidade tradicional em termos de segmentação, mensuração e otimização contínua. Plataformas como Google Ads e Facebook Ads permitem que até mesmo pequenas empresas com orçamentos limitados alcancem audiências altamente segmentadas, pagando apenas quando usuários interagem com anúncios (modelo CPC — custo por clique) ou visualizam conteúdo (modelo CPM — custo por mil impressões).

Fenômenos recentes como a utilização do Tiktok\Youtube Shorts\Reels do Instagram e das LLMs no lugar dos mecanismos de busca, como anunciar ou otimizar/direcionar os resultados para sua empresa nestes meios são objeto de estudo profundo do marketing digital no momento.

Análise e mensuração constituem diferenciais fundamentais do marketing digital. Ao contrário do marketing tradicional, onde mensuração precisa de resultados frequentemente mostra-se desafiadora, o ambiente digital permite rastreamento detalhado de métricas como impressões, cliques, taxas de conversão, custo de aquisição de cliente e retorno sobre

investimento. Ferramentas de web analytics, como Google Analytics, fornecem dados granulares sobre comportamento do usuário, permitindo otimização contínua de estratégias.

2.1.4. Marketing Digital no Contexto Brasileiro e das PMEs

A aplicação do marketing digital assume características particulares quando analisada no contexto de Micro, Pequenas e Médias Empresas brasileiras. Dados do SEBRAE em parceria com a FGV (2024) revelam que PMEs representam parcela substancial do tecido empresarial brasileiro, contribuindo significativamente para geração de emprego e renda. Contudo, estas empresas enfrentam desafios específicos relacionados a recursos limitados — financeiros, humanos e tecnológicos — que influenciam sua capacidade de adotar e utilizar efetivamente ferramentas de marketing digital.

Pesquisas recentes sobre maturidade digital de PMEs brasileiras (SEBRAE/ABDI, 2023, 2024) evidenciam processo de digitalização em curso, mas ainda com heterogeneidade significativa. Enquanto algumas empresas alcançam níveis de maturidade digital intermediários ou avançados, parcela considerável permanece em estágios iniciais, caracterizados por presença digital incipiente e uso limitado de ferramentas digitais para processos de negócio. No que se refere especificamente ao marketing digital, observa-se que conectar e engajar clientes através de canais digitais representa objetivo reconhecido, mas persistem dificuldades em profissionalizar presença online, produzir conteúdo de qualidade com regularidade e mensurar efetivamente resultados.

A utilização pelas PMEs de agências de marketing digital e de micro influenciadores serão possíveis ocorrências encontradas nas pesquisas *in loco*.

Calais e Santos (2016, citados em Grison et al., 2019) identificam barreiras específicas que dificultam uso de marketing digital por PMEs: incapacidade para produzir materiais publicitários com qualidade necessária, falta de domínio e familiaridade no uso das mídias sociais, falta de tempo ou pessoal para ocupar-se com atividades de marketing digital, dificuldade de interpretação dos dados coletados e avaliação do que números obtidos realmente significam, e custos com pessoal e pagamento de taxas para publicação.

Estas barreiras conectam-se diretamente aos construtos teóricos que fundamentam estudos sobre adoção de tecnologia, particularmente o modelo UTAUT (Unified Theory of Acceptance and Use of Technology), que será explorado em profundidade em seção posterior desta fundamentação teórica. A expectativa de esforço, condições facilitadoras e expectativa de performance — construtos centrais do UTAUT — manifestam-se concretamente nas dificuldades relatadas por gestores de PMEs ao tentarem implementar estratégias de marketing digital.

Não obstante estes desafios, o marketing digital oferece oportunidades particularmente relevantes para PMEs. Democratização de acesso a ferramentas, redução de barreiras de entrada (comparadas à publicidade em mídias tradicionais), possibilidade de segmentação precisa e mensuração de resultados constituem atrativos significativos. Além disso, características do ambiente digital — como valorização de autenticidade, importância do engajamento comunitário e relevância do conteúdo sobre orçamentos publicitários volumosos — podem favorecer pequenas empresas que investem em relacionamento genuíno com clientes.

2.1.5. A Inteligência Artificial como Nova Fronteira do Marketing Digital

A difusão recente de ferramentas de Inteligência Artificial generativa, particularmente a partir de 2022, inaugura novo capítulo na evolução do marketing digital. Ferramentas como ChatGPT, Gemini, Claude e outras baseadas em Large Language Models (LLMs) democratizam acesso a capacidades que anteriormente requeriam expertise técnica especializada ou investimentos substanciais: criação de conteúdo textual, geração de imagens, análise de dados, personalização em escala e automação de interações com clientes.

Para PMEs, estas ferramentas apresentam potencial particularmente transformador, endereçando precisamente algumas das barreiras identificadas anteriormente. A dificuldade em produzir conteúdo de qualidade com regularidade pode ser mitigada através de assistentes de IA que auxiliam na geração de textos para redes sociais, blogs, e-mail marketing e descrições de produtos. A complexidade analítica pode ser reduzida através de ferramentas que processam dados e geram insights em linguagem natural. A personalização em escala, antes privilégio de grandes empresas com recursos para sofisticados sistemas de CRM e automação, torna-se acessível através de chatbots inteligentes e sistemas de recomendação.

Contudo, a introdução da IA no marketing digital também suscita questões sobre autenticidade, transparência, vieses algorítmicos e impactos sobre o trabalho humano. Kanezaki et al. (2024) argumentam que a IA não substitui o toque humano necessário para construir relações genuínas com consumidores, mas sim complementa e potencializa capacidades analíticas e criativas dos profissionais. Esta sinergia entre inteligência humana e artificial emerge como tema central para compreensão do marketing digital contemporâneo.

2.1.6. Síntese - Marketing Digital

O percurso analítico empreendido nesta seção estabeleceu fundamentos conceituais do marketing moderno, traçou evolução do marketing tradicional ao digital e examinou aplicações contemporâneas do marketing digital, com atenção particular ao contexto brasileiro e aos desafios e oportunidades enfrentados pelas PMEs. Observou-se que o marketing digital não representa ruptura total com princípios do marketing tradicional, mas sim sua extensão e adaptação às possibilidades e exigências do ambiente tecnológico contemporâneo.

Os 4Ps permanecem relevantes como estrutura analítica, embora suas manifestações tenham sido profundamente transformadas pela digitalização. Produto incorpora componentes digitais e experiências online; preço adota dinâmicas algorítmicas e modelos de negócio digitais; praça reconfigura-se através de e-commerce, marketplaces e omnicanalidade; promoção multiplica-se em miríade de canais e formatos digitais. A inovação faz com que surjam novos Ps relevantes ao contexto digital: personalização, participação, precisão analítica.

Para PMEs brasileiras, o marketing digital apresenta-se simultaneamente como oportunidade e desafio. Oportunidade de ampliar alcance, engajar clientes, competir mais efetivamente e mensurar resultados. Desafio relacionado a recursos limitados, falta de conhecimento especializado, dificuldades de produção de conteúdo e complexidade analítica. A recente difusão de ferramentas de Inteligência Artificial generativa adiciona nova camada a

este cenário, potencialmente democratizando acesso a capacidades sofisticadas de marketing digital.

Esta compreensão do marketing digital prepara terreno para aprofundamento, na próxima seção, das particularidades das Micro, Pequenas e Médias Empresas como objeto de estudo. Será necessário examinar características específicas destas organizações — suas limitações de recursos, processos decisórios, estruturas organizacionais e contextos competitivos — para compreender adequadamente como adotam e utilizam ferramentas de marketing digital, especialmente aquelas baseadas em Inteligência Artificial. A intersecção entre marketing digital, especificidades das PME e tecnologias emergentes de IA constitui o núcleo da investigação que este trabalho se propõe a realizar.

2.2 Micro, Pequenas e Médias Empresas (PMEs) e o Marketing Digital

2.2.1 Caracterização das PME no Contexto Brasileiro

As micro e pequenas empresas ocupam posição central no tecido econômico brasileiro, representando não apenas a quase totalidade dos estabelecimentos empresariais do país, mas também desempenhando papel estratégico na geração de empregos e renda. Compreender as especificidades estruturais, a participação econômica e o nível de maturidade digital dessas organizações é fundamental para contextualizar os desafios e oportunidades relacionados à adoção de marketing digital e, mais recentemente, de ferramentas baseadas em inteligência artificial generativa.

Esta seção apresenta três eixos de análise: os critérios de classificação adotados no Brasil, a participação quantitativa das PMEs na economia nacional e os níveis de maturidade digital por porte, setor e região, estabelecendo assim as bases estruturais necessárias para a investigação proposta neste estudo.

2.2.1.1. Critérios de Classificação de PMEs no Brasil

A definição de micro e pequenas empresas no contexto brasileiro envolve a coexistência de dois critérios principais: o número de pessoas ocupadas e a receita bruta anual. O critério baseado em pessoal ocupado, adotado pelo Instituto Brasileiro de Geografia e Estatística (IBGE) e amplamente utilizado pelo Serviço Brasileiro de Apoio às Micro e Pequenas Empresas (SEBRAE), classifica as empresas segundo o setor de atividade e o número de colaboradores (Serviço Brasileiro de Apoio às Micro e Pequenas Empresas [SEBRAE], 2024).

Para os setores de comércio e serviços, são consideradas microempresas aquelas com até 9 pessoas ocupadas e pequenas empresas aquelas com 10 a 49 pessoas ocupadas. Já para o setor industrial, os limites são ampliados: microempresas possuem até 19 pessoas ocupadas, enquanto pequenas empresas empregam de 20 a 99 pessoas. As médias empresas, por sua vez, empregam de 50 a 99 pessoas nos setores de comércio e serviços e de 100 a 499 pessoas na indústria (SEBRAE, 2024).

Paralelamente, a Lei Complementar 123/2006, que institui o regime tributário do Simples Nacional, adota o critério de receita bruta anual para fins fiscais. Segundo esta legislação, os microempreendedores individuais (MEI) podem auferir receita de até R\$

81.000 (oitenta e um mil reais) por ano; as microempresas (ME), até R\$ 360.000 (trezentos e sessenta mil reais) anuais; e as empresas de pequeno porte (EPP), de R\$ 360.000,01 (trezentos e sessenta mil reais e um centavo) a R\$ 4.800.000 (quatro milhões e oitocentos mil reais) por ano. Para fins de classificação de média empresa podemos considerar a definição do BNDES (Banco Nacional de Desenvolvimento Econômico e Social) o qual considera empresa de médio porte a empresa com faturamento anual superior a R\$ 4,8 milhões e até R\$ 300 milhões.

Este estudo adota o critério de pessoal ocupado, alinhando-se à metodologia empregada pelo SEBRAE no relatório "Participação de Micro e Pequenas Empresas na Economia Nacional" (SEBRAE, 2024), dado que esta forma de classificação corresponde à organização oficial das estatísticas do IBGE e permite maior comparabilidade com as bases de dados nacionais.

2.2.1.2. Participação das PMEs na Economia Brasileira

A relevância econômica das micro e pequenas empresas no Brasil é expressiva e consistente ao longo do tempo. Em 2021, essas empresas responderam por 26,5% do valor adicionado gerado nas atividades investigadas — que incluem indústria extrativa mineral, indústria de transformação, construção, comércio e serviços —, excluindo agropecuária, intermediação financeira, saúde, educação e administração pública (SEBRAE, 2024). Esse percentual, embora inferior aos 28,3% registrados em 2018, ainda representa mais de um quarto da produção econômica do país. A trajetória histórica revela que a participação das

PMEs no valor adicionado atingiu um pico de 30% em 2016, em meio à crise econômica, retornando ao patamar histórico nos anos subsequentes (SEBRAE, 2024).

Essa oscilação sugere que as PMEs desempenham papel de amortecedor econômico em períodos de recessão, mantendo sua estrutura operacional e preservando empregos, enquanto as médias e grandes empresas tendem a crescer mais rapidamente em fases de retomada econômica.

No que se refere à geração de empregos, as micro e pequenas empresas foram responsáveis por 48,9% da população ocupada em 2021 nas atividades analisadas, ante 51,6% em 2018 (SEBRAE, 2024). Historicamente, as PMEs mantiveram-se como principal empregador nacional, representando cerca de 50% das ocupações entre 2010 e 2021. Além disso, essas empresas constituem 97,72% do total de estabelecimentos empresariais brasileiros, evidenciando sua capilaridade e onipresença no território nacional. Em termos absolutos, de 2010 a 2021, as PMEs foram responsáveis por 48% do aumento da população ocupada, correspondendo a 2,4 milhões de pessoas, mesmo considerando o período pandêmico (SEBRAE, 2024).

A análise setorial demonstra que comércio e serviços são as atividades em que as PMEs possuem maior participação no valor adicionado total da economia. Em 2021, o comércio representou 8,7% do valor adicionado total (ante 9,7% em 2018), enquanto os serviços responderam por 11,6% (ante 12,4% em 2018) (SEBRAE, 2024). A indústria de transformação manteve participação estável, variando de 3,0% em 2018 para 3,2% em 2021 (SEBRAE, 2024). Essa concentração em comércio e serviços é coerente com a natureza

dessas atividades, que apresentam menores economias de escala e barreiras de entrada reduzidas, permitindo que as micro e pequenas empresas sejam mais competitivas.

Observa-se um fenômeno paradoxal no desempenho das Micros e Pequenas brasileiras: embora essas empresas tenham apresentado crescimento nominal de 16,9% no valor adicionado em 2021 (após queda de 0,7% em 2020), sua participação relativa no valor adicionado total da economia diminuiu 1,8 pontos percentuais entre 2018 e 2021 (SEBRAE, 2024). Esse aparente contraditório revela que, apesar do crescimento absoluto das Micros e Pequenas, as médias e grandes empresas expandiram-se em ritmo ainda mais acelerado, particularmente durante a recuperação econômica pós-pandemia.

2.2.1.3. Níveis de Maturidade Digital das PMEs: Análise Setorial e Regional

A transformação digital das micro e pequenas empresas brasileiras tem avançado de forma lenta e heterogênea, conforme evidenciado pelas pesquisas de maturidade digital realizadas pelo SEBRAE em parceria com a Agência Brasileira de Desenvolvimento Industrial (ABDI). O Indicador de Maturidade Digital (IMD), medido em uma escala de 0 a 80 pontos, classifica as empresas em quatro níveis: Analógico (0-20 pontos), Emergente (20-50 pontos), Intermediário (50-80 pontos) e Líder Digital (acima de 80 pontos) (Serviço Brasileiro de Apoio às Micro e Pequenas Empresas & Agência Brasileira de Desenvolvimento Industrial [SEBRAE & ABDI], 2023, 2024). Este indicador é composto por seis objetivos estratégicos de digitalização, avaliados por meio de 20 práticas digitais específicas: (1) conectar e engajar clientes, (2) estabelecer novas bases de competição, (3) construir uma organização orientada a dados, (4) inovar mais rápido e colaborativamente, (5)

gerar mais valor para os clientes e (6) adotar tecnologias habilitadoras (SEBRAE & ABDI, 2024).

Em 2024, a média nacional do IMD atingiu 35 pontos, posicionando as PMEs brasileiras no Nível 2 (Emergente) (SEBRAE & ABDI, 2024). Este resultado indica que a maioria das empresas se encontra em estágios iniciais de transformação digital, avançando em práticas específicas, mas ainda operando com modelos de negócios tradicionais e enfrentando dificuldades significativas para romper a barreira da digitalização estratégica. É importante ressaltar que houve mudança metodológica entre as pesquisas de 2023 e 2024, com alteração na escala Likert utilizada, o que impede comparações diretas entre os IMD de 48,25 pontos (2023) e 35 pontos (2024) (SEBRAE & ABDI, 2023, 2024). Não obstante essa limitação, a tendência observada em ambas as edições aponta para uma concentração de empresas no Nível Emergente e uma redução progressiva do percentual de empresas totalmente analógicas, que caiu de 14,9% em 2022 para 8,4% em 2024 (SEBRAE & ABDI, 2023, 2024). Cerca de 23% das PMEs concentram-se entre 20 e 50 pontos, confirmando o posicionamento majoritário no estágio emergente (SEBRAE & ABDI, 2024).

A análise por porte revela padrão claro e consistente: quanto maior o porte da empresa, maior sua maturidade digital. Em 2024, os microempreendedores individuais (MEI) registraram IMD médio de 31 pontos, as microempresas (ME) alcançaram 40 pontos e as empresas de pequeno porte (EPP) atingiram 42 pontos (SEBRAE & ABDI, 2024). Essa progressão reflete as diferenças estruturais entre os portes, notadamente em termos de capacidade de investimento, disponibilidade de recursos humanos qualificados e complexidade organizacional. Os MEI, em grande parte compostos por empreendedores

individuais com recursos limitados, enfrentam maiores dificuldades para implementar práticas digitais avançadas, enquanto as EPP dispõem de estrutura ligeiramente mais robusta para investir em sistemas de gestão, *cloud computing* e capacitação de colaboradores.

No recorte setorial, as diferenças são quase imperceptíveis em 2024, sugerindo homogeneidade na adoção digital entre os principais segmentos econômicos. O comércio lidera discretamente, com IMD de 36 pontos, seguido pelos serviços (35 pontos) e pela indústria (34 pontos) (SEBRAE & ABDI, 2024). Essa diferença marginal contrasta com a trajetória histórica: em 2023, utilizando metodologia distinta, o setor de serviços apresentou IMD de 48,45, seguido pela indústria (48,28) e comércio (48,02) (SEBRAE & ABDI, 2023). Embora as escalas não sejam diretamente comparáveis, observa-se que o comércio tem demonstrado evolução mais acelerada, possivelmente impulsionada pela proliferação de *marketplaces* digitais, ferramentas de *e-commerce* e pressões competitivas para presença *on-line*. A relativa paridade entre os setores em 2024 sugere que os desafios e oportunidades da transformação digital transcendem características setoriais específicas, afetando de maneira transversal as micro e pequenas empresas brasileiras.

A análise regional evidencia disparidades moderadas, mas significativas. A região Sul lidera o ranking nacional com IMD de 36 pontos, seguida pelo Nordeste (35 pontos), Sudeste (34,5 pontos), Norte (34,3 pontos) e Centro-Oeste (34,3 pontos) (SEBRAE & ABDI, 2024). Essas diferenças podem estar associadas a fatores como infraestrutura de telecomunicações, níveis de escolaridade dos empreendedores, dinamismo econômico regional e presença de políticas públicas de incentivo à digitalização. A análise por unidade federativa revela amplitude ainda maior: Santa Catarina registra o IMD mais elevado do país (38,4 pontos),

seguida por Acre (37,2), Pernambuco (36,7), Rio Grande do Sul (36,2) e Piauí (36,2) (SEBRAE & ABDI, 2024). No extremo oposto, Pará (32,5), Mato Grosso (32,6), Amapá (32,9), Rio de Janeiro (33,1) e Ceará (33,2) apresentam os IMD mais baixos (SEBRAE & ABDI, 2024). São Paulo, lócus desta pesquisa, registra IMD de 35,1 pontos, praticamente idêntico à média nacional de 35 (SEBRAE & ABDI, 2024). Esse resultado é particularmente relevante para a presente investigação, pois justifica Capivari-SP como lócus representativo da realidade nacional em termos de maturidade digital, permitindo inferências mais amplas a partir dos achados locais.

A decomposição do IMD pelos seis objetivos estratégicos revela assimetrias preocupantes na forma como as PMEs têm conduzido sua transformação digital. O objetivo melhor avaliado foi "Tecnologias Habilitadoras", com média de 2,0 pontos (em escala de 0 a 4), indicando que as empresas têm conseguido adotar infraestrutura tecnológica básica, notadamente acesso à internet em banda larga (53,9% concordam totalmente) e uso de serviços de nuvem (*cloud computing*) (SEBRAE & ABDI, 2024). Em contrapartida, o objetivo pior avaliado foi "Inovar mais rápido e colaborativamente", com média de apenas 1,4 pontos, seguido por "Construir uma organização orientada a dados" (1,6 pontos) (SEBRAE & ABDI, 2024). Esse padrão revela um *gap* estrutural crítico: as PMEs possuem a infraestrutura tecnológica necessária, mas não conseguem transformá-la em capacidades estratégicas como inovação de produtos/serviços, análise de dados para tomada de decisão e colaboração com parceiros externos.

A prática individual mais implementada pelas PMEs foi "Digitalizar e integrar processos de negócios", com 23,1% das empresas afirmando implementação total e 20,8%

em estágio avançado de implantação (SEBRAE & ABDI, 2023, 2024). Em contraste, "Inovar colaborativamente" foi a prática menos adotada: 40% das empresas discordaram totalmente da afirmação de ter desenvolvido produtos ou serviços em cooperação com outras empresas, *startups*, centros tecnológicos ou parceiros no último ano (SEBRAE & ABDI, 2023, 2024). A segunda prática menos implementada foi "Participar de plataformas de negócios" (*marketplaces*), com 37,4% das empresas afirmando não adotar essa estratégia (SEBRAE & ABDI, 2023). Esses resultados sugerem que a digitalização das PMEs brasileiras tem se concentrado primordialmente em eficiência operacional interna — digitalização de processos, adoção de sistemas de gestão — em detrimento de transformações estratégicas que envolvam novos modelos de negócio, monetização digital, uso avançado de *analytics* e ecossistemas colaborativos.

Os principais desafios apontados pelas PMEs para avançar na agenda digital foram: falta de recursos para investir (33,95% das empresas), dificuldade em acessar pessoas ou empresas com capacidade técnica (20,76%) e desconhecimento sobre quais prioridades de investimento adotar (12,78%) (SEBRAE & ABDI, 2024). Esses obstáculos evidenciam não apenas limitações financeiras, mas também lacunas de conhecimento e capacitação que impedem as empresas de traçar estratégias digitais coerentes e sustentáveis.

Um alerta metodológico adicional deve ser considerado: as pesquisas de maturidade digital do SEBRAE-ABDI foram realizadas em 2023 e 2024, após a difusão em massa das ferramentas de inteligência artificial generativa (novembro de 2022). Entretanto, os questionários de maturidade digital não incluíram perguntas específicas sobre o uso de IA generativa para criação de conteúdo, automação de atendimento, análise preditiva ou

personalização de marketing. Assim, é plausível que parte das PMEs já estivesse utilizando ferramentas como ChatGPT, Gemini ou ferramentas de geração de imagens, mas essa prática não estava capturada formalmente nos indicadores oficiais de maturidade digital.

Confirmando esta suspeita metodológica, a pesquisa nacional "Transformação Digital nos Pequenos Negócios 2025", realizada pelo SEBRAE entre março e maio de 2025 com 7.182 empresas, trouxe pela primeira vez perguntas específicas sobre o uso de ferramentas de inteligência artificial pelas PMEs brasileiras (Serviço Brasileiro de Apoio às Micro e Pequenas Empresas [SEBRAE], 2025). Os resultados revelam um fenômeno notável: quando perguntados espontaneamente se já haviam utilizado algum tipo de IA, 44% dos empreendedores responderam afirmativamente; entretanto, quando estimulados com uma lista de 12 aplicações digitais específicas baseadas em IA, este percentual saltou para 80% (SEBRAE, 2025). Esta discrepância entre mensuração espontânea e estimulada evidencia que uma parcela substancial dos pequenos empreendedores brasileiros utiliza ferramentas de IA sem necessariamente reconhecê-las como tal, sugerindo baixa literacia digital conceitual mesmo quando há apropriação tecnológica prática.

No detalhamento por aplicações específicas, 51% dos empreendedores afirmaram já ter utilizado ferramentas de IA generativa para texto (ChatGPT, Deep Seek, Copilot, Gemini), 44% utilizaram ferramentas de geração de imagens, 52% aplicativos que otimizam fotos, e 41% *chatbots* no WhatsApp (SEBRAE, 2025). Esses dados confirmam empiricamente que, após a difusão massiva das ferramentas de IA generativa a partir de novembro de 2022, as PMEs brasileiras efetivamente adotaram essas tecnologias em proporções significativas. Ademais, a pesquisa identificou padrões demográficos importantes: o uso de ChatGPT é mais

prevalente entre empreendedores jovens (até 34 anos: 71%), com pós-graduação (80%), mulheres (57% vs. 47% dos homens) e pessoas LGBTQI+ (69% vs. 52% dos heterossexuais) (SEBRAE, 2025). Por porte, as diferenças são marcantes: enquanto 65% das EPP reportam uso de IA, apenas 35% dos MEI o fazem, reproduzindo o padrão de desigualdade digital observado nos indicadores de maturidade (SEBRAE, 2025). Regionalmente, o Sudeste lidera com 48% de uso espontâneo de IA, seguido pelo Sul (43%), sendo São Paulo o estado com maior adoção (51%) (SEBRAE, 2025). Setorialmente, o setor de serviços apresenta maior utilização de IA (49%), seguido pelo comércio (41%) e indústria (32%), sugerindo que a natureza das atividades influencia significativamente o padrão de adoção tecnológica (SEBRAE, 2025).

Não obstante a relevância desses dados quantitativos inéditos, subsistem lacunas teóricas e empíricas significativas que justificam a presente investigação. Primeiro, a pesquisa SEBRAE 2025, por sua natureza quantitativa e abrangência nacional, não captura *como* essas ferramentas estão sendo integradas às estratégias de marketing digital, *quais* práticas específicas foram reconfiguradas, *quais* desafios emergem na adoção, nem *como* os gestores avaliam o impacto dessas tecnologias nos resultados empresariais. Segundo, a pergunta sobre uso de IA foi colocada de forma genérica ("na empresa ou fora"), impedindo distinguir entre uso pessoal e uso estratégico organizacional. Terceiro, não há análise da relação entre adoção de IA e os seis objetivos estratégicos de digitalização do IMD, deixando em aberto se as ferramentas de IA estão sendo utilizadas apenas para eficiência operacional (como sugerem os indicadores de 2024) ou também para inovação, análise de dados e criação de novos modelos de negócio. Quarto, embora a pesquisa identifique que 33,95% das PMEs

apontam falta de recursos financeiros como principal obstáculo à digitalização e 20,76% indicam dificuldade de acesso a capacidade técnica, não há aprofundamento sobre como a adoção de IA generativa — tecnologias com custo de entrada significativamente menor que soluções empresariais tradicionais — pode estar alterando essa equação de barreiras. Por fim, os dados nacionais agregados podem mascarar especificidades regionais, setoriais e contextuais que são melhor capturadas por estudos de caso em profundidade.

Dessa forma, embora a pesquisa SEBRAE 2025 preencha parcialmente a lacuna quantitativa sobre adoção de IA pelas PMEs, permanece em aberto a compreensão qualitativa profunda de *como* essa adoção está efetivamente transformando (ou não) as práticas de marketing digital em contextos específicos, especialmente em municípios fora dos grandes centros metropolitanos. É precisamente essa lacuna que a presente investigação visa preencher por meio de um estudo de caso múltiplo em Capivari-SP, aliando rigor metodológico qualitativo à fundamentação no modelo UTAUT para compreender não apenas *se* as PMEs estão usando IA, mas *como, por quê, com quais resultados e enfrentando quais barreiras*. Esta lacuna temporal e temática entre os indicadores de maturidade digital e a realidade da adoção de IA generativa reforça a relevância da presente investigação, que busca compreender justamente como as PMEs estão adotando essas ferramentas no contexto do marketing digital, em um cenário de baixa maturidade digital geral, mas com acesso crescente a tecnologias de IA acessíveis e de baixa barreira de entrada.

2.2.2 Desafios e Oportunidades do Marketing Digital para PMEs

Após a caracterização da relevância estrutural das Micro, Pequenas e Médias Empresas (PMEs) para a economia, conforme detalhado na seção anterior, temos de analisar a complexa relação que essas organizações estabelecem com o marketing digital. Este ambiente apresenta uma dualidade intrínseca: ao mesmo tempo que oferece oportunidades sem precedentes para nivelar o campo competitivo, impõe desafios que, muitas vezes, exacerbam as vulnerabilidades de recursos e capacitação inerentes a esses negócios. Esta seção, portanto, dedica-se a examinar criticamente esta dinâmica, explorando as barreiras estruturais que limitam a adoção e a eficácia das estratégias digitais e, em contrapartida, as oportunidades estratégicas percebidas pelos gestores.

2.2.2.1 Barreiras Estruturais à Adoção Digital: Uma Perspectiva Baseada em Fatores Críticos

A literatura acadêmica tem consistentemente documentado os obstáculos que dificultam a plena incorporação do marketing digital pelas PMEs. Taiminen e Karjaluoto (2015) oferecem um *framework* robusto para categorizar essas barreiras, agrupando-as em três eixos interdependentes.

Primeiramente, os fatores ligados à firma e ao gestor emergem como barreiras primárias. A falta de conhecimento técnico e estratégico sobre as ferramentas digitais, aliada a uma percepção de baixa relevância ou retorno incerto do investimento, frequentemente leva a uma subutilização ou a uma abordagem reativa e não planejada do marketing digital.

Em segundo lugar, os fatores relacionados a recursos são talvez os mais evidentes. A escassez de recursos humanos especializados para gerir campanhas, as restrições orçamentárias que impedem investimentos em ferramentas pagas ou em publicidade, e, de forma crucial, a falta de tempo dos gestores — que frequentemente acumulam múltiplas funções — constituem um obstáculo operacional significativo.

Por fim, os fatores ambientais, como a intensidade da concorrência e a rápida evolução do comportamento do consumidor, podem paradoxalmente inibir a ação. Em vez de motivar a adoção, a velocidade das mudanças pode gerar uma sensação de incapacidade de acompanhar o ritmo, levando à inércia.

2.2.2.2 Oportunidades Percebidas: Dimensões de Geração de Valor

Em contrapartida a essas barreiras, o marketing digital abre um leque de oportunidades estratégicas que são amplamente percebidas pelos gestores. Beynon et al. (2021), ao estudarem os benefícios do acesso à banda larga por PMEs, identificaram duas dimensões centrais de geração de valor que podem ser extrapoladas para o marketing digital como um todo.

A primeira é a dimensão de Comunicação e Competitividade. As PMEs reconhecem o valor das ferramentas digitais para aprimorar a capacidade de resposta a clientes e fornecedores, monitorar a concorrência de forma mais eficaz, melhorar a comunicação interna e externa e, conseqüentemente, otimizar processos, resultando em ganhos de eficiência. Esta dimensão reflete a percepção de que o digital é um canal fundamental para se manter relevante e competitivo no mercado contemporâneo. A segunda, e muitas vezes

subestimada, é a dimensão de Segurança e Gestão de Risco. A adoção de tecnologias digitais, como serviços baseados em nuvem para marketing e gestão, é crescentemente percebida como uma oportunidade para aumentar a segurança de dados e aprimorar a continuidade dos negócios, mitigando riscos operacionais.

2.2.2.3 A Realidade Empírica no Contexto das PMEs

Estudos empíricos corroboram essa tensão entre desafios e oportunidades. No contexto brasileiro, uma pesquisa com PMEs em um município de pequeno porte revelou um paradoxo interessante: embora 100% dos entrevistados utilizassem alguma ferramenta de marketing digital, a prática estava massivamente concentrada em uma única plataforma (Facebook, com 97,2% de uso), e as principais barreiras relatadas eram a falta de tempo e a dificuldade em criar conteúdo de qualidade (Grison et al., 2019). Isso evidencia que a adoção, embora ampla, permanece em um estágio operacional e de baixa sofisticação estratégica, alinhando-se diretamente às barreiras de recursos e conhecimento.

De forma similar, uma investigação com PMEs portuguesas do setor têxtil (B2B) identificou que os principais obstáculos à implementação de ferramentas digitais eram a falta de recursos humanos especializados e o baixo investimento (Castanheira et al., 2022), reforçando a consistência desses desafios para além das fronteiras nacionais e setoriais. Ambos os estudos ilustram que, embora as oportunidades sejam reconhecidas, as barreiras estruturais continuam a ser um fator determinante na limitação da profundidade e da eficácia das práticas de marketing digital nas PMEs.

2.2.2.4 Síntese e a Nova Fronteira Tecnológica

A literatura acadêmica, consolidada por revisões sistemáticas recentes (p. ex., Has & Knežević, 2024), desenha um panorama claro e consistente do marketing digital em PMEs até o início da década de 2020. Trata-se de um campo marcado pela tensão entre as oportunidades de ampliar a competitividade e a comunicação, e as barreiras persistentes de recursos, tempo e conhecimento especializado. Este cenário, contudo, foi dramaticamente interpelado por uma ruptura tecnológica.

É precisamente neste nexos de desafios históricos e disrupção tecnológica que a Inteligência Artificial (IA) emerge não apenas como mais uma ferramenta, mas como um potencial agente reconfigurador. A difusão massiva de ferramentas de IA generativa, acessíveis e de baixo custo a partir de 2022, postula uma solução teórica direta para as barreiras documentadas: a escassez de tempo pode ser mitigada pela automação (*Mechanical AI*), a falta de conhecimento técnico pela capacidade analítica das plataformas (*Thinking AI*), e a dificuldade de personalização pela emulação de interações humanas (*Feeling AI*). Diante disso, torna-se imperativo dissecar o que a IA de fato representa no contexto do marketing, para então analisar se seu potencial teórico encontra eco na realidade prática das PMEs. A seção seguinte, portanto, aprofunda os conceitos e tipologias da IA aplicada ao marketing

2.3 Inteligência artificial Aplicada ao Marketing

2.3.1 Conceitos e Tipologias de IA (IA Mecânica, de Pensamento e Sentimental)

Para analisar de forma rigorosa como a Inteligência Artificial (IA) reconfigura as práticas de marketing, é necessário superar uma enrijecida da tecnologia e adotar uma taxonomia que decomponha suas diversas capacidades. Diferentes ferramentas de IA executam funções distintas, que vão desde a simples automação de tarefas até a complexa análise de emoções humanas. Compreender essas nuances é o primeiro passo para avaliar seu impacto estratégico, especialmente no contexto de recursos limitados das PMEs. Nesse sentido, a literatura acadêmica recente oferece *frameworks* robustos que categorizam a IA em se tratando de marketing com base em suas funcionalidades e níveis de inteligência.

2.3.1.1 Um *Framework* Estratégico para a IA no Marketing: As Três Inteligências

Um dos *frameworks* mais influentes para a aplicação estratégica da IA no marketing é o proposto por Huang e Rust (2021). Os autores sugerem uma categorização baseada em uma analogia com as capacidades humanas, dividindo a IA em três níveis de inteligência, cada um associado a um benefício estratégico primordial.

O primeiro nível é a **Inteligência Mecânica (*Mechanical AI*)**, cuja função principal é automatizar tarefas físicas ou cognitivas que sejam rotineiras e repetitivas. Esta é a forma mais básica de IA, focada em executar processos com consistência e em grande escala, como a coleta massiva de dados, a distribuição de produtos por drones ou a automação de processos robóticos (RPA) em atividades de *back-office*. Seu principal benefício estratégico é a

padronização, que resulta em ganhos de eficiência, consistência, confiabilidade e redução de custos operacionais.

O segundo nível é a **Inteligência de Pensamento (*Thinking AI*)**, que se refere à capacidade da IA de processar grandes volumes de dados, incluindo dados não estruturados como textos e imagens, para aprender, reconhecer padrões, tirar conclusões e apoiar decisões. Esta categoria engloba as tecnologias de *machine learning* e *deep learning* que fundamentam, por exemplo, os sistemas de recomendação, a análise preditiva e a criação de conteúdo. O benefício estratégico central derivado da *Thinking AI* é a **personalização**, permitindo que as empresas customizem ofertas, comunicações e experiências em uma escala antes inatingível.

Por fim, o terceiro e mais avançado nível é a **Inteligência Sentimental (*Feeling AI*)**. Esta dimensão se concentra na capacidade da IA de analisar, interpretar e responder a emoções e sentimentos humanos em interações bidirecionais. Aplicações como análise de sentimento em mídias sociais e *chatbots* avançados capazes de detectar o tom do cliente são exemplos dessa capacidade. O benefício estratégico correspondente é a habilidade de personalizar não apenas o produto ou a mensagem, mas o próprio relacionamento com o cliente, cultivando laços mais fortes.

2.3.1.2 Contextualizando a Evolução: Da Automação de Processos à Era Generativa

Para compreender a magnitude da transformação atual, é útil contrastar o *framework* de Huang e Rust (2021) com a visão da IA que prevalecia no ambiente de negócios antes da massificação das ferramentas generativas. Davenport e Ronanki (2018), em um influente artigo na *Harvard Business Review*, categorizaram as aplicações de IA em três frentes: automação de processos, correspondente à IA Mecânica; *cognitive insight* (insight cognitivo), análogo à IA de Pensamento; e *cognitive engagement* (engajamento cognitivo), relacionado à IA Sentimental.

Embora as categorias sejam conceitualmente paralelas, a natureza da tecnologia dentro delas evoluiu drasticamente. O "insight cognitivo" de 2018, baseado em análise preditiva, não antecipava a capacidade da "IA de Pensamento" de hoje de *gerar* conteúdo original e complexo, como textos, códigos e imagens. Essa capacidade generativa, popularizada por modelos de linguagem de grande escala (LLMs) a partir de novembro de 2022, representa uma ruptura qualitativa que democratizou o acesso a capacidades de *Thinking AI* antes restritas a grandes corporações com times robustos de cientistas de dados.

2.3.1.3 Aprofundando as Dimensões da IA e suas Limitações

Para refinar ainda mais a compreensão dessas tipologias, o *framework* complementar de Davenport et al. (2020) oferece três dimensões analíticas: os níveis de inteligência, os tipos de tarefa e a forma de manifestação da tecnologia. A distinção entre "automação de tarefas" vs. "consciência de contexto" aprofunda a diferença entre a IA Mecânica, que opera em domínios bem definidos, e as formas mais avançadas de IA, que aspiram a "aprender a aprender". A capacidade de analisar diferentes tipos de tarefa, especialmente a transição da

análise de dados puramente numéricos para dados não numéricos (texto, voz, imagens), é o que verdadeiramente potencializa a IA de Pensamento e a IA Sentimental. A forma de manifestação (física/robô vs. virtual/software) é, por fim, uma dimensão crucial para delimitar o escopo desta pesquisa, que se concentra nas aplicações virtuais de baixo custo, acessíveis às PMEs.

É fundamental, contudo, reconhecer as limitações inerentes a cada tipo de IA, como apontado por Huang e Rust (2021). A IA Mecânica, ao automatizar a coleta de dados, muitas vezes perde o contexto em que esses dados foram gerados, o que é especialmente problemático para informações de natureza emocional. A IA de Pensamento frequentemente opera como uma "caixa-preta" (*black box*), tornando difícil para os gestores compreenderem o "porquê" de uma recomendação, além de carregar o risco de perpetuar e amplificar vieses presentes nos dados de treinamento. Por fim, a IA Sentimental enfrenta os desafios da imaturidade tecnológica (as máquinas ainda não "sentem" genuinamente) e da não prontidão do cliente, que pode demonstrar resistência a interagir com agentes não humanos em contextos emocionais.

2.3.2 Aplicações de IA em Marketing Digital

A Inteligência Artificial manifesta-se no marketing através de um portfólio diversificado de aplicações que variam significativamente em complexidade, custo e impacto estratégico. Para compreender sistematicamente essas aplicações, esta seção adota a tipologia proposta por Huang e Rust (2021), organizando a discussão pelos quatro elementos do composto mercadológico — Produto, Preço, Praça e Promoção. Esta estrutura permite

identificar onde cada nível de inteligência artificial (Mecânica, de Pensamento e Sentimental) gera valor específico, estabelecendo as bases conceituais para posterior análise de sua viabilidade em contextos de recursos limitados.

2.3.2.1 Produto/Consumidor: Da Padronização à Personalização

No eixo Produto/Consumidor, a IA atua em um espectro que vai desde a otimização de processos operacionais até a personalização granular da oferta de valor, reconfigurando fundamentalmente a relação entre empresas e clientes.

IA Mecânica — Automação de Processos de Conhecimento do Produto: Neste nível fundamental, a IA automatiza a coleta, integração e padronização de dados relacionados ao uso de produtos. Sistemas baseados em telemetria e Internet das Coisas (IoT) permitem monitoramento contínuo do ciclo de vida do produto, gerando bases de dados consistentes para análise e melhoria contínua (Huang & Rust, 2021). A automação de processos robóticos (RPA) estende-se à criação de catálogos digitais, processamento de descrições técnicas e padronização de ativos visuais, reduzindo erros humanos e liberando recursos para atividades estratégicas.

IA de Pensamento — Personalização Baseada em Dados: A capacidade de modelos de machine learning de processar simultaneamente dados estruturados (histórico de compras, preferências declaradas) e não estruturados (imagens, textos, padrões de navegação) viabiliza personalização em escala anteriormente inatingível. Huang e Rust (2021) documentam o caso da Stitch Fix, onde algoritmos analisam múltiplas fontes de dados — incluindo painéis visuais do Pinterest — para gerar recomendações de produtos que são

posteriormente refinadas por estilistas humanos. Este modelo de cocriação homem-máquina exemplifica como a IA pode aumentar capacidades humanas ao invés de simplesmente substituí-las.

Sistemas de recomendação, amplamente implementados em plataformas de e-commerce, utilizam algoritmos de filtragem colaborativa e baseada em conteúdo para prever preferências individuais e apresentar sugestões contextualizadas. A construção automatizada de *buyer personas* via análise de clusters em dados de CRM representa outra aplicação consolidada de IA de Pensamento, permitindo segmentação sofisticada sem exigir equipes especializadas em ciência de dados.

IA Sentimental — Relacionamento Adaptativo: Na fronteira mais avançada, a IA busca reconhecer e responder a estados emocionais e necessidades afetivas dos clientes. Agentes conversacionais avançados demonstram capacidade de adaptar estilo comunicacional, tom e conteúdo baseados em análise de sentimento em tempo real (Huang & Rust, 2021). Para marcas corporativas, esta tecnologia permite criar interações que refletem personalidade e valores organizacionais, transformando pontos de contato transacionais em oportunidades de fortalecimento de relacionamento.

Contudo, aplicações de IA Sentimental exigem governança rigorosa. A definição clara de limites éticos, transparência sobre a natureza automatizada das interações e mecanismos robustos de escalamento para atendimento humano em situações complexas são condições necessárias para implementação responsável.

2.3.2.2 Preço/Custo: Da Automação Transacional à Otimização Dinâmica

No eixo Preço/Custo, a IA transforma processos que vão desde a simples automação de transações financeiras até a otimização algorítmica sofisticada de estratégias de precificação.

IA Mecânica — Automação de Processos Financeiros: A automação de processos robóticos (RPA) é extensivamente utilizada para padronizar rotinas de back office financeiro, incluindo processamento de faturas, reconciliação de pagamentos, atualização de registros contábeis e gestão de cobrança, por exemplo. Esta automação reduz ciclos operacionais, minimiza erros humanos e libera capital humano para análises estratégicas.

Sistemas de lead scoring automatizado utilizam modelos preditivos para classificar oportunidades comerciais por probabilidade de conversão, permitindo priorização inteligente de recursos comerciais e redução de custos de aquisição de clientes (CAC) (Järvinen & Taiminen, 2016).

IA de Pensamento — Precificação Algorítmica: Algoritmos de otimização de preços integram múltiplos sinais — elasticidade de demanda, preços competitivos, níveis de estoque, sazonalidade, comportamento de navegação — para ajustar preços dinamicamente . Companhias aéreas e plataformas de e-commerce foram pioneiras em *yield management* algorítmico, maximizando receita através de ajustes de preço em tempo real baseados em modelos preditivos de demanda.

Esta prática, contudo, demanda protocolos robustos de teste, controles de viés algorítmico e conformidade regulatória para evitar discriminação de preços e garantir percepção de justiça pelos consumidores.

IA Sentimental — Negociação Contextual e Seus Limites Éticos: Modelos que inferem estado emocional e urgência a partir de padrões linguísticos poderiam, teoricamente, modular ofertas em interações síncronas (Huang & Rust, 2021). Contudo, esta fronteira permanece regulatoriamente sensível, especialmente sob legislações de proteção de dados como GDPR e LGPD, que impõem restrições ao processamento de inferências sobre estados emocionais sem consentimento explícito.

Aplicações responsáveis concentram-se em detectar frustração ou confusão para priorizar escalamento humano, não em explorar vulnerabilidades emocionais para extração de valor econômico.

2.3.2.3 Praça/Conveniência: Da Automação Logística à Antecipação Preditiva

No eixo Praça/Conveniência, a IA otimiza tanto fluxos físicos da cadeia de suprimentos quanto a experiência do cliente em canais de distribuição.

IA Mecânica — Automação de Operações Logísticas: Robótica, drones e visão computacional ampliam significativamente a acurácia e eficiência em centros de distribuição. A Amazon, por exemplo, utiliza mais de 200.000 robôs Kiva em seus *fulfillment centers*, automatizando a movimentação de inventário e reduzindo o tempo de processamento de pedidos.

Importante notar que estas implementações representam trajetórias tecnológicas em consolidação, com projetos-piloto bem-sucedidos mas ainda não constituindo padrão universal, especialmente para PMEs.

IA de Pensamento — Capacidade Preditiva Logística: A capacidade de prever demanda no nível do cliente individual permite práticas como *anticipatory shipping*, onde produtos são movidos para centros de distribuição próximos antes da realização do pedido (Huang & Rust, 2021). O sucesso de tais estratégias é condicionado a um alto grau de acerto preditivo e desenho logístico eficiente para gestão de devoluções.

Sistemas de previsão de demanda baseados em machine learning integram variáveis diversas — sazonalidade, tendências de mercado, dados macroeconômicos a previsão meteorológica — para otimizar níveis de estoque em múltiplos escalões da rede de distribuição (Syntetos et al., 2016).

IA Sentimental — Interação Personalizada em Pontos de Contato: Robôs sociais e assistentes virtuais em ambientes físicos podem acolher clientes, fornecer orientações e personalizar interações. Sistemas de análise de sentimento via visão computacional podem identificar clientes confusos ou frustrados, acionando protocolos de assistência proativa.

Contudo, tais aplicações levantam questões sensíveis de privacidade e consentimento, exigindo transparência sobre coleta de dados biométricos e conformidade com legislações específicas.

2.3.2.4 Promoção/Comunicação: Epicentro da Transformação Generativa

O eixo Promoção/Comunicação foi o mais profundamente transformado pela IA, tornando-se o epicentro da revolução generativa que democratiza o acesso a capacidades criativas.

IA Mecânica — Orquestração Programática de Mídia: Compra programática de mídia, agendamento automatizado de publicações em múltiplas plataformas e retargeting dinâmico representam aplicações consolidadas de automação que permitem escalar operações com controle preciso sobre frequência, segmentação e custos. uso de ferramentas como *Google Analytics e Meta Ads*

IA de Pensamento — Personalização Criativa em Escala: A capacidade de gerar e variar mensagens mantendo consistência de marca representa salto qualitativo. O caso da Lexus, que utilizou IBM Watson para analisar 15 anos de campanhas premiadas e criar roteiro de comercial, tornou-se proof of concept da criatividade assistida por IA (IBM, 2018).

A ruptura definitiva, contudo, veio com a IA generativa. Modelos de linguagem de grande escala (LLMs) como GPT, Claude e Gemini demonstraram capacidade de gerar textos persuasivos, criativos publicitários, roteiros e até código para landing pages mediante prompts em linguagem natural.

2.3.2.5. IA Generativa em PMEs

Kanezaki et al. (2024) fornecem evidência empírica fundamental ao demonstrarem que o ChatGPT é capaz de conceber campanhas de marketing completas e personalizadas para diferentes nichos, adaptando tom de voz, mensagens-chave e propostas de valor a partir de briefings estruturados. Este estudo representa uma das primeiras validações científicas da aplicabilidade prática de IA generativa em marketing estratégico para pequenos negócios, não apenas em tarefas operacionais.

Ferramentas text-to-image como NanoBanana, Seadream, DALL·E, Midjourney e Stable Diffusion expandiram capacidades generativas para domínio visual, permitindo criação rápida de ilustrações e variações criativas para testes.

IA Sentimental — Análise Afetiva e Ressonância Emocional: Ferramentas de *affective analytics* empregam visão computacional para capturar reações emocionais de audiências a anúncios em tempo real. Análise de sentimento em redes sociais baseada em processamento de linguagem natural permite monitorar percepção de marca e identificar crises emergentes.

A seleção de influenciadores digitais também se beneficia de IA Sentimental, com algoritmos avaliando autenticidade de audiência, alinhamento de valores e ressonância emocional genuína do conteúdo histórico.

2.3.2.6 Síntese Conceitual

A análise das aplicações de IA através dos 4Ps, estruturada pela tipologia de Huang e Rust (2021), revela um continuum de sofisticação tecnológica. A IA Mecânica oferece ganhos imediatos de eficiência operacional, constituindo ponto de entrada mais acessível. A IA de Pensamento habilita personalização em escala e decisões orientadas a dados, representando fronteira de diferenciação competitiva. A IA Sentimental busca replicar capacidades humanas de empatia, constituindo uma fronteira mais avançada e eticamente sensível.

Ferramentas com Jasper IA e Hubsport apresentam uma ampla gama de funções em marketing

Crucialmente, o eixo Promoção/Comunicação concentra a maior densidade de aplicações maduras e acessíveis, explicando sua predominância em discussões sobre IA no marketing. Esta concentração tem implicações diretas para PMEs, conforme será explorado na seção seguinte.

2.3.3 IA como recurso estratégico para PME's

As aplicações da Inteligência Artificial detalhadas na seção anterior transcendem a mera otimização de tarefas operacionais; elas representam o potencial para se tornarem um recurso organizacional capaz de gerar vantagem competitiva sustentável. Diante da crescente acessibilidade de ferramentas de IA generativa, emerge uma questão central para as Pequenas e Médias Empresas (PMEs): essas tecnologias podem ser consideradas uma fonte de vantagem competitiva duradoura, ou são apenas ferramentas passageiras disponíveis para todos? Para responder a essa questão, esta seção ancora-se na Visão Baseada em Recursos (RBV), uma das teorias mais influentes da gestão estratégica.

A RBV, consolidada por Barney (1991), postula que a fonte da vantagem competitiva de uma firma não reside primordialmente em seu posicionamento no mercado externo, mas em seus recursos e capacidades internas. A premissa central é que os recursos são distribuídos de forma heterogênea entre as empresas e possuem baixa mobilidade, o que

significa que as diferenças entre elas podem ser duradouras. Para que um recurso gere uma vantagem competitiva sustentável, ele deve atender a quatro critérios, conhecidos pelo acrônimo VRIN: ser **Valioso**, **Raro**, **Inimitável** e ter ausência de **Substitutos** estrategicamente equivalentes.

2.3.3.1 Análise da IA como Recurso para PMEs sob a Ótica do VRIN

Ao aplicar o *framework* VRIN às ferramentas de IA no contexto específico das PMEs, é possível realizar uma análise crítica de seu potencial estratégico.

Valor (Value): Um recurso é valioso se permite à firma explorar oportunidades ou neutralizar ameaças em seu ambiente competitivo. As aplicações de IA discutidas anteriormente (2.3.2) atendem claramente a este critério. Para uma PME, a capacidade de gerar conteúdo de alta qualidade com baixo custo, automatizar o atendimento ao cliente, obter *insights* de dados sem uma equipe de analistas e personalizar a comunicação em escala são formas diretas de aumentar a eficiência e competir de forma mais eficaz com empresas de maior porte, explorando oportunidades de nicho e neutralizando a ameaça da irrelevância digital.

Raridade (Rarity): Um recurso é raro se não for possuído por um grande número de concorrentes atuais ou potenciais. Aqui, emerge um paradoxo. As *ferramentas* de IA em si (softwares como ChatGPT, Gemini, Grok, Claude, entre outras LLMs e plataformas de automação) estão se tornando commodities amplamente acessíveis e, portanto, não são raras. Contudo, a **capacidade organizacional** de integrar essas ferramentas de forma sinérgica com a estratégia, a cultura, os processos e o conhecimento tácito da PME é, sim, um recurso raro.



A vantagem competitiva não reside na posse da tecnologia, mas na sua aplicação única, autêntica e no *know-how* desenvolvido internamente para extrair dela um valor único.

Inimitabilidade (*Inimitability*): Um recurso é imperfeitamente imitável quando outras firmas não conseguem obtê-lo ou desenvolvê-lo. A tecnologia de IA é, em sua essência, altamente imitável. Um concorrente pode assinar os mesmos serviços de IA que outra PME utiliza. Entretanto, a vantagem se torna difícil de imitar quando a IA está profundamente entrelaçada com os recursos socialmente complexos da firma. Barney (1991) aponta a **ambiguidade causal** e a **complexidade social** como fontes primárias de inimitabilidade.

A **complexidade social** emerge quando o valor de um recurso está atrelado à teia de relações, cultura e reputação da empresa. Imagine uma PME familiar do setor de agronegócio em Capivari-SP, cuja cultura é baseada em décadas de relacionamento de confiança com produtores locais. A implementação de uma IA que analisa dados de safras e otimiza a comunicação com esses parceiros, utilizando uma linguagem que reflete o "tom de voz" do fundador (aprendida a partir de anos de mensagens trocadas), cria uma eficiência operacional entrelaçada com um capital social inimitável. Um concorrente pode comprar a mesma IA, mas não pode replicar a cultura de confiança e as relações interpessoais que a tornam eficaz. O recurso valioso não é a IA isoladamente, mas a **simbiose da IA com o capital social da firma**, um ativo acumulado ao longo do tempo e de difícil replicação.

A **ambiguidade causal** ocorre quando os concorrentes não conseguem discernir com clareza a relação de causa e efeito entre os recursos da empresa e seu sucesso, gerando uma

"imitabilidade incerta". Considere uma pequena varejista de moda local que utiliza uma IA generativa para criar suas campanhas nas redes sociais. O sucesso viral dessas campanhas pode não derivar apenas do algoritmo, mas da combinação da IA com o **conhecimento tácito** da gestora sobre as preferências estéticas da comunidade de Capivari e da forma como ela "guia" a IA com *prompts* que refletem essa intuição local. Para um concorrente, é impossível decifrar se o sucesso vem da ferramenta, da habilidade da gestora, do conhecimento do contexto ou da sinergia única entre os três. Essa incerteza sobre *o que* imitar funciona como uma poderosa barreira à imitação.

Não-Substituibilidade (Non-substitutability): O critério final exige que não existam substitutos estrategicamente equivalentes para o recurso, ou seja, recursos diferentes que possam ser usados para implementar a mesma estratégia. No contexto das PMEs, poder-se-ia considerar a **terceirização para agências de marketing** ou o uso de **plataformas de automação não baseadas em IA** como potenciais substitutos. Contudo, esses são estrategicamente imperfeitos. A terceirização pode executar tarefas, mas dificilmente replica a integração da IA com o conhecimento tácito e a cultura da firma, substituindo a *função*, mas não o *recurso* estratégico. A automação tradicional, por sua vez, pode substituir as funções da IA Mecânica (como agendamento de posts), mas carece das capacidades de aprendizado, adaptação e geração de *insights* da IA de Pensamento. Portanto, para o contexto de restrição de recursos das PMEs, a **combinação integrada** de baixo custo, alta eficiência, capacidade de aprendizado e personalização em escala oferecida pelas ferramentas de IA pode não ter um substituto estrategicamente equivalente e acessível.

2.3.3.2 Validação Empírica em Economias em Desenvolvimento

A análise teórica do potencial da IA como recurso estratégico é corroborada por evidências empíricas recentes. Em um estudo com 316 PMEs no Paquistão, um contexto de economia em desenvolvimento comparável ao Brasil, Amin et al. (2025) investigaram o impacto da transformação digital na performance de marketing. Os resultados indicaram que a transformação digital, que engloba a adoção de tecnologias como a IA, tem um impacto positivo e significativo na performance de marketing das PMEs. O estudo também destacou o papel mediador crucial das mídias sociais, sugerindo que é na aplicação da tecnologia aos canais de comunicação que grande parte do valor é gerado. Esta pesquisa valida empiricamente o critério de "Valor" do *framework* VRIN, demonstrando que, na prática, a adoção de recursos digitais avançados está, de fato, se traduzindo em desempenho superior para as PMEs.

2.3.3.3 Síntese e Transição para o Modelo de Aceitação

A análise sob a ótica da RBV sugere que a Inteligência Artificial transcende a condição de mera ferramenta e se posiciona como um potencial recurso estratégico capaz de gerar vantagem competitiva para as PMEs. A sustentabilidade dessa vantagem, contudo, não reside na simples posse da tecnologia — que é cada vez mais acessível e imitável — mas na sua aplicação contextual, integrada à cultura e aos processos socialmente complexos que caracterizam cada empresa. As evidências empíricas de economias em desenvolvimento reforçam o impacto positivo dessa adoção na performance.

Nessa perspectiva, o potencial estratégico da inteligência artificial se manifesta em sua capacidade de aumentar as competências do gestor, permitindo-lhe superar limitações de

recursos para o alcance de objetivos estratégicos. Uma vez estabelecido que a IA *pode ser* um recurso estratégico (o quê), a próxima questão fundamental é entender *por que e como* os gestores de PMEs decidem adotar (ou não) essa tecnologia. Se o recurso é valioso, quais fatores impulsionam ou inibem sua aceitação? Para responder a essa questão, é necessário recorrer a modelos teóricos que expliquem a aceitação e o uso de tecnologia em nível individual e organizacional, tema que será abordado na seção seguinte com a apresentação do Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT).

2.4 Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT)

Para compreender os fatores que impulsionam ou inibem a adoção de inovações tecnológicas — como as ferramentas de Inteligência Artificial no marketing digital — por parte dos gestores de PMEs, é fundamental recorrer a modelos teóricos consolidados. A literatura sobre aceitação de tecnologia oferece um arcabouço robusto para analisar este fenômeno. Dentre os diversos modelos propostos, a Teoria Unificada de Aceitação e Uso de Tecnologia (UTAUT), desenvolvida por Venkatesh et al. (2003), destaca-se por sua abrangência e alto poder preditivo. No entanto, para compreender a magnitude de sua contribuição, é essencial analisar primeiramente seu principal precursor genealógico: o Modelo de Aceitação de Tecnologia (TAM).

A investigação sobre aceitação de tecnologia foi, por décadas, dominada pelo Modelo de Aceitação de Tecnologia (TAM) de Davis (1989), que postulava a Utilidade Percebida e a Facilidade de Uso Percebida como os principais determinantes da adoção.

Contudo, a aplicação do TAM ao contexto de PMEs brasileiras adotando IA Generativa revelaria limitações significativas. O modelo de Davis (1989) concentra-se em crenças individuais e ignora duas forças cruciais no ecossistema de uma PME: a **influência do ambiente externo** — como a pressão de concorrentes ou a recomendação de consultores — e as **condições concretas de recursos** da organização, como a disponibilidade de verba, infraestrutura tecnológica e, principalmente, capacitação técnica interna. Limitar a análise a 'utilidade' e 'facilidade' seria negligenciar precisamente as barreiras que a literatura sobre PMEs (e.g., Taiminen & Karjaluoto, 2015) aponta como críticas.

2.4.1 Construtos Centrais do UTAUT

A principal contribuição do UTAUT foi integrar oito modelos teóricos proeminentes em um único e coeso *framework*, superando a fragmentação teórica que caracterizava a área de pesquisa em aceitação de tecnologia. Sua origem, contudo, está diretamente ligada ao influente trabalho de Davis (1989) sobre o TAM, que estabeleceu os pilares conceituais da área. O TAM postula que a aceitação de uma tecnologia pelo usuário é determinada primordialmente por duas crenças fundamentais: a Utilidade Percebida e a Facilidade de Uso Percebida, as mesmas que serão abordadas na apresentação do framework UTAUT a seguir.

Em seus estudos empíricos, Davis (1989) demonstrou que a Utilidade Percebida possuía uma correlação significativamente mais forte com o uso auto reportado do que a Facilidade de Uso Percebida ($r = 0,63$ vs. $r = 0,45$, respectivamente), sugerindo que os

usuários priorizam os resultados e benefícios de desempenho que uma tecnologia pode oferecer.

Avançando a partir dessas bases, Venkatesh et al. (2003) desenvolveram o UTAUT com o objetivo de criar uma teoria unificada. O modelo sintetiza construtos de oito teorias anteriores, incluindo o TAM, e propõe quatro determinantes diretos da intenção de uso e do comportamento. Os quatro construtos centrais são:

1. **Expectativa de Desempenho (*Performance Expectancy*):** Definida como "o grau em que um indivíduo acredita que usar o sistema o ajudará a obter ganhos no desempenho do trabalho"(Venkatesh et al., 2003, p. 447), este construto é o preditor mais forte da intenção de uso e absorve diretamente o conceito de Utilidade Percebida do TAM.

2. **Expectativa de Esforço (*Effort Expectancy*):** Definida como "o grau de facilidade associado ao uso do sistema" (Venkatesh et al., 2003, p. 450), captura a essência da Facilidade de Uso Percebida do TAM. Seu impacto tende a ser mais significativo nos estágios iniciais de experiência com a tecnologia, diminuindo com o tempo.

3. **Influência Social (*Social Influence*):** Definida como "o grau em que um indivíduo percebe que outros importantes acreditam que ele ou ela deve usar o novo sistema" (Venkatesh et al., 2003, p. 451), este construto incorpora as normas sociais e a pressão de pares, um fator crucial em ambientes organizacionais que não era um componente central do TAM original.

4. **Condições Facilitadoras (*Facilitating Conditions*):** Definidas como "o grau em que um indivíduo acredita que uma infraestrutura organizacional e técnica existe para

apoiar o uso do sistema" (Venkatesh et al., 2003, p. 453), abrangem a percepção de recursos e suporte disponíveis para o usuário.

Além desses construtos, o UTAUT introduziu quatro variáveis moderadoras chave — Gênero, Idade, Experiência e Voluntariedade de Uso — que ajustam a força das relações entre os construtos e a intenção/comportamento. Essa inclusão foi fundamental para o sucesso do modelo, que demonstrou um poder explicativo substancialmente superior aos seus predecessores, explicando aproximadamente 70% da variância na intenção de uso dos usuários.

Em síntese, a passagem do TAM para o UTAUT representou uma ampliação significativa do escopo teórico. Enquanto o TAM se concentrava nas crenças individuais sobre utilidade e facilidade, o UTAUT enriqueceu o modelo ao incorporar as dimensões social e contextual, além de moderadores que explicam as diferenças entre subgrupos de usuários, tornando-se um framework mais completo para analisar a aceitação de tecnologia em ambientes organizacionais complexos.

2.4.2 Aplicações do UTAUT em Contextos de PMEs

Apesar de o UTAUT ter sido originalmente validado em grandes organizações, sua robustez teórica levou a diversas aplicações em outros contextos, incluindo o de Micro, Pequenas e Médias Empresas (MPMEs), que possuem particularidades como restrição de recursos e processos decisórios menos formalizados. A análise de estudos empíricos em cenários análogos ao desta pesquisa é fundamental para justificar a adequação do modelo.

Estudos recentes em economias emergentes demonstram a validade externa do arcabouço TAM/UTAUT. Em Moçambique, Uchavo (2025) conduziu uma pesquisa com 332 MPMEs do setor de alimentos e bebidas para analisar os fatores que influenciam a adoção do Marketing Digital. O estudo partiu do problema de que, apesar de representarem 97% das empresas, as MPMEs respondiam por apenas 10% das exportações do país, sendo o marketing digital uma via de baixo custo para acessar mercados internacionais. Utilizando o TAM como base, a pesquisa confirmou que a Utilidade Percebida e a Facilidade de Uso Percebida são os fatores que influenciam significativamente a adoção do Marketing Digital, explicando em conjunto 73% da taxa de adoção. A análise de regressão logística reforçou que, à medida que esses dois construtos aumentam, as chances de adoção do marketing digital também aumentam. Os achados de Uchavo (2025) fornecem uma forte evidência empírica de que os pilares do TAM — e, por extensão, os construtos de Expectativa de Desempenho e Expectativa de Esforço do UTAUT — mantêm sua validade no universo das MPMEs em economias em desenvolvimento.

Avançando do precursor TAM para o modelo unificado, Abdat (2020) aplicou diretamente o UTAUT para investigar a adoção de aplicativos de mídias sociais por 162 PMEs na Indonésia. O modelo demonstrou alto poder preditivo, explicando 61% da variância na intenção comportamental de adotar essas ferramentas. Os resultados foram particularmente reveladores: os construtos Expectativa de Desempenho ($\beta=0.24$), Influência Social ($\beta=0.30$) e Condições Facilitadoras ($\beta=0.27$) tiveram um efeito positivo e significativo sobre a intenção de adoção. Em contrapartida, a Expectativa de Esforço não teve efeito significativo. A não significância da Expectativa de Esforço, aliada à forte influência dos

fatores sociais e das condições de suporte, sugere um padrão de comportamento típico de PMEs, onde, uma vez que os gestores são convencidos dos benefícios de desempenho e percebem uma pressão social para adotar uma tecnologia, eles estão dispostos a superar uma curva de aprendizado mais íngreme, desde que haja suporte técnico e organizacional disponível.

No contexto brasileiro, Nishi e Löbner (2018) realizaram um estudo para a "(Re)construção do Modelo UTAUT 2 em Contexto Brasileiro", focando no uso de smartphones com uma amostra de 1.900 consumidores. Embora o foco não tenha sido em PMEs, a pesquisa é metodologicamente relevante por ter realizado um rigoroso processo de validação e adaptação transcultural do instrumento de pesquisa e por ter testado a inclusão de moderadores adaptados à realidade nacional, como escolaridade, renda e estado civil. Um dos achados importantes foi que, no modelo final ajustado, o construto Condições Facilitadoras não teve relação com a *Intenção Comportamental*, mas sim uma ligação direta com o *Comportamento de Uso*. Este resultado, alinhado ao UTAUT original, reforça a necessidade de se investigar como os construtos e moderadores do UTAUT se manifestam em subgrupos específicos do contexto brasileiro, como os gestores de PMEs.

Finalmente, a relevância gerencial do modelo é confirmada por Sharabati et al. (2024), que analisaram o impacto do marketing digital na performance de 190 PMEs de marketing na Jordânia, utilizando o TAM como lente teórica. O estudo concluiu que "o marketing digital é essencial para a eficácia das PMEs, como um motor da transformação digital, levando a resultados econômicos mais fortes e a uma presença de mercado ampliada". Os autores reforçam que a adoção de tecnologia depende da utilidade e da facilidade de uso

percebidas, e que essa adoção se traduz em melhor performance, incluindo "retornos financeiros, visibilidade de mercado e satisfação do cliente". Este estudo recente valida empiricamente a cadeia causal que vai da percepção positiva da tecnologia (núcleo do TAM/UTAUT) à adoção e, conseqüentemente, à melhoria do desempenho organizacional.

Em conjunto, estas pesquisas sustentam a aplicabilidade do arcabouço teórico do UTAUT para a presente investigação. As evidências demonstram que seus construtos são preditores robustos da adoção de tecnologias de marketing digital por PMEs em diferentes culturas, e sua adaptação ao contexto brasileiro já foi iniciada. Contudo, persiste uma lacuna na literatura sobre a aplicação do modelo UTAUT de forma integrada para explicar especificamente a adoção de ferramentas de *Inteligência Artificial* no marketing digital por *gestores de PMEs no Brasil*, justificando a relevância deste estudo.

2.5 Síntese da Fundamentação Teórica e *Framework* Conceitual

Os capítulos anteriores apresentaram os principais construtos teóricos que fundamentam esta investigação: o Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT), as taxonomias de Inteligência Artificial aplicadas ao marketing, e as especificidades das Micro, Pequenas e Médias Empresas (PMEs) no contexto brasileiro. Embora cada corpo teórico forneça lentes analíticas valiosas isoladamente, a compreensão do fenômeno complexo da adoção de ferramentas de IA por PMEs no marketing digital demanda uma integração crítica dessas perspectivas (Venkatesh et al., 2003; Huang & Rust, 2021; Has & Knežević, 2024).

A presente seção tem como objetivo articular esses frameworks em um modelo conceitual integrado que orientará tanto a coleta quanto a análise de dados empíricos.

Inicialmente, estabelece-se o UTAUT como estrutura organizadora principal, dada sua robustez empírica e aplicabilidade a contextos organizacionais (seção 2.5.1). Em seguida, enriquece-se cada construto do UTAUT com frameworks complementares: a taxonomia das três inteligências de Huang e Rust (2021) para operacionalizar a Expectativa de Desempenho (seção 2.5.2), a categorização de tarefas de Davenport et al. (2020) para contextualizar a Expectativa de Esforço (seção 2.5.3), e evidências empíricas sobre drivers e barreiras específicas de PMEs para aprofundar a compreensão de Influência Social e Condições Facilitadoras (seção 2.5.4). Por fim, apresenta-se o framework conceitual integrado (seção 2.5.5) e reconhece-se a abertura metodológica para categorias emergentes (seção 2.5.6), garantindo coerência com a abordagem qualitativa interpretativa adotada.

2.5.1 Modelo UTAUT como Base Estruturante

O Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT), proposto por Venkatesh et al. (2003), constitui o framework organizador principal desta pesquisa. Sua escolha fundamenta-se em três pilares: robustez empírica, aplicabilidade organizacional e flexibilidade contextual. Primeiro, o modelo demonstra poder explicativo superior aos modelos predecessores, explicando aproximadamente 70% da variância na intenção de uso de tecnologia em contextos organizacionais (Venkatesh et al., 2003), superando significativamente o Modelo de Aceitação de Tecnologia original - TAM (Davis, 1989), que alcançava cerca de 40% de variância explicada. Segundo, diferentemente do UTAUT2 (Venkatesh et al., 2012), desenvolvido especificamente para contextos de consumo

individual, o UTAUT original foi concebido para adoção de tecnologias em ambientes organizacionais, alinhando-se ao escopo desta investigação que examina decisões de gestores de PMEs. Terceiro, a estrutura do UTAUT permite incorporação de construtos contextuais adicionais sem comprometer sua integridade teórica, viabilizando a integração com frameworks específicos de IA e de PMEs.

O UTAUT integra oito modelos teóricos antecessores - incluindo o TAM (Davis, 1989) - destilando-os em quatro construtos centrais que influenciam a intenção comportamental e o uso efetivo de tecnologia: Expectativa de Desempenho (Performance Expectancy), Expectativa de Esforço (Effort Expectancy), Influência Social (Social Influence) e Condições Facilitadoras (Facilitating Conditions). Adicionalmente, o modelo identifica quatro variáveis moderadoras - gênero, idade, experiência e voluntariedade de uso - que afetam a força das relações entre os construtos (Venkatesh et al., 2003).

Adaptando esses construtos ao contexto desta pesquisa:

a) Performance Expectancy (Expectativa de Desempenho): Definida originalmente como "o grau em que o indivíduo acredita que usar o sistema ajudará a obter ganhos de desempenho no trabalho" (Venkatesh et al., 2003, p. 447), este construto refere-se, nesta investigação, aos benefícios percebidos pelos gestores de PMEs quanto ao uso de ferramentas de IA para aprimorar práticas de marketing digital. A natureza desses benefícios será operacionalizada através da taxonomia de Huang e Rust (2021), permitindo identificar se gestores percebem ganhos em eficiência operacional (*Mechanical AI*), capacidade analítica (*Thinking AI*) ou personalização de relacionamento (*Feeling AI*).

b) Effort Expectancy (Expectativa de Esforço): Originalmente conceituada como

"o grau de facilidade associada ao uso do sistema" (Venkatesh et al., 2003, p. 450), este construto captura percepções sobre a complexidade técnica versus usabilidade de ferramentas de IA. No contexto de PMEs, caracterizadas por limitações de recursos humanos especializados (Has & Knežević, 2024), a percepção de esforço torna-se particularmente crítica. A taxonomia de tarefas de Davenport et al. (2020) permitirá diferenciar níveis de complexidade: automação de tarefas rotineiras (Task Automation) demanda menor esforço que tarefas exigindo compreensão contextual (Context Awareness) ou suporte a decisões estratégicas (Decision Support).

c) Social Influence (Influência Social): Definida como "o grau em que o indivíduo percebe que outros importantes acreditam que ele deveria usar o sistema" (Venkatesh et al., 2003, p. 451), a Influência Social manifesta-se, em contextos de PMEs, através de pressão competitiva (necessidade de acompanhar concorrentes), benchmarking setorial e influência de stakeholders externos como fornecedores de tecnologia, consultorias e associações empresariais (Beynon et al., 2021). Estudos em regiões periféricas demonstram que investimentos públicos em infraestrutura digital amplificam essa influência social, criando expectativas normativas de adoção tecnológica (Beynon et al., 2021).

d) Facilitating Conditions (Condições Facilitadoras): Conceituadas originalmente como "o grau em que o indivíduo acredita que existe infraestrutura organizacional e técnica para suportar o uso do sistema" (Venkatesh et al., 2003, p. 453), as Condições Facilitadoras abrangem, no contexto de PMEs, três dimensões críticas: recursos financeiros (orçamento disponível para ferramentas de IA e infraestrutura tecnológica), conhecimento técnico (competências digitais dos gestores e equipes) e estrutura organizacional (formalização de

processos e cultura de inovação). A literatura documenta que essas três dimensões constituem as principais barreiras à adoção de tecnologias digitais por PMEs (Has & Knežević, 2024; Taiminen & Karjaluoto, 2015).

A adaptação do UTAUT para o contexto brasileiro justifica-se pela validação transcultural realizada por Nishi e Löbner (2018), que confirmaram a aplicabilidade do modelo em amostras brasileiras, embora com nuances específicas nas variáveis moderadoras. Adicionalmente, aplicações recentes do modelo em estudos sobre adoção de tecnologias por PMEs em economias emergentes (Sharabati et al., 2024; Uchavo, 2025) demonstram sua validade para contextos organizacionais com recursos limitados, reforçando sua adequação à investigação proposta.

2.5.2 Integração com a Taxonomia das Três Inteligências (Huang & Rust, 2021)

Para operacionalizar o construto de Expectativa de Desempenho, esta pesquisa incorpora a taxonomia das três inteligências de IA proposta por Huang e Rust (2021), que categoriza capacidades de Inteligência Artificial com base no tipo de trabalho que realizam, estabelecendo paralelo com inteligências humanas (mecânica, analítica e emocional).

Huang e Rust (2021) argumentam que diferentes aplicações de IA no marketing requerem tipos distintos de inteligência. A *Mechanical AI* (inteligência mecânica) refere-se à capacidade de executar tarefas repetitivas, estruturadas e orientadas por regras, substituindo trabalho físico e cognitivo rotineiro. No contexto de marketing digital, manifesta-se em automação de postagens em redes sociais, agendamento de campanhas, respostas automáticas

a perguntas frequentes e geração de relatórios padronizados. A *Thinking AI* (inteligência analítica) envolve processamento complexo de dados, reconhecimento de padrões, análise preditiva e geração de insights a partir de grandes volumes de informação. Suas aplicações incluem análise de sentimento em mídias sociais, segmentação avançada de público, otimização de lances em publicidade digital e previsão de comportamento de consumidores. Por fim, a *Feeling AI* (inteligência emocional) simula capacidades humanas de empatia, compreensão emocional e construção de relacionamentos, manifestando-se através de chatbots com processamento de linguagem natural, personalização de conteúdo baseada em estados emocionais inferidos e sistemas de recomendação sensíveis ao contexto (Huang & Rust, 2021).

A conexão dessa taxonomia com o construto de Expectativa de Desempenho do UTAUT ocorre através da especificação dos tipos de benefícios percebidos pelos gestores. Estudos sobre adoção de tecnologia demonstram que percepções de benefício não são unidimensionais: gestores podem valorizar ganhos em eficiência operacional (redução de tempo/custos), capacidade analítica (melhores decisões) ou qualidade de relacionamento com clientes (Davenport & Ronanki, 2018). A taxonomia de Huang e Rust (2021) permite mapear esses benefícios de forma estruturada:

- **Benefícios de Mechanical AI → Expectativa de ganhos em eficiência operacional:** automação libera tempo da equipe para atividades estratégicas, reduz erros em tarefas repetitivas e permite escala de operações sem crescimento proporcional de recursos humanos.

- **Benefícios de *Thinking AI* → Expectativa de ganhos em capacidade analítica:**

acesso a insights anteriormente inacessíveis, fundamentação de decisões em dados quantitativos, identificação proativa de oportunidades e ameaças competitivas.

- **Benefícios de *Feeling AI* → Expectativa de ganhos em personalização e engajamento:** interações mais relevantes e contextualizadas com clientes, aumento de taxa de conversão através de recomendações personalizadas, fortalecimento de relacionamento e lealdade.

Para PMEs, caracterizadas por limitações severas de recursos humanos e financeiros (Has & Knežević, 2024), a priorização entre esses tipos de inteligência pode variar conforme maturidade digital e estratégia competitiva. PMEs em estágios iniciais de transformação digital tendem a priorizar *Mechanical AI*, buscando ganhos rápidos através de automação de tarefas operacionais (Huang & Rust, 2021). Conforme amadurecem digitalmente e acumulam dados estruturados, podem avançar para *Thinking AI*, extraíndo valor analítico de suas bases de dados (Davenport et al., 2020). A adoção de *Feeling AI*, por demandar maior sofisticação técnica e volumes substanciais de dados comportamentais, pode representar estágio mais avançado de adoção, embora ferramentas de IA generativa recentes (como chatbots baseados em LLMs, sendo várias as disponíveis no mercado, mas algumas a citar: Zenvia, Blip, Manychat, Botpress,) possam estar democratizando o acesso a essa categoria (Huang & Rust, 2021).

Importa ressaltar que o framework de Huang e Rust (2021) foi desenvolvido antes da difusão massiva de modelos de linguagem de grande escala (LLMs) - o artigo foi aceito em setembro de 2020 e publicado em 2021, enquanto ferramentas como ChatGPT foram lançadas apenas em novembro de 2022. É necessário anotar também que o rápido avanço

dessas ferramentas faz com que a janela de um ano, já seja uma janela de tempo notável para análise. Assim, algumas capacidades de IA generativa podem transcender ou hibridizar as categorias propostas. Chatbots baseados em LLMs, por exemplo, combinam elementos de *Thinking AI* (compreensão contextual sofisticada) e *Feeling AI* (respostas empáticas) com facilidade de implementação característica de *Mechanical AI*. Esta tensão entre o framework teórico pré-2022 e as capacidades contemporâneas de IA generativa constitui contribuição potencial deste estudo, permitindo examinar empiricamente como PMEs percebem e categorizam ferramentas de IA pós-difusão de LLMs.

2.5.3 Integração com Taxonomia de Tarefas de IA (Davenport et al., 2020)

Para contextualizar o construto de Expectativa de Esforço, incorpora-se a taxonomia de tarefas de Davenport et al. (2020), que categoriza aplicações de IA com base em três dimensões: níveis de inteligência requeridos, tipos de tarefas executadas e forma de manifestação (virtual ou robótica). Para os propósitos desta pesquisa, focada em marketing digital, privilegia-se a dimensão de níveis de inteligência, que se desdobra em três categorias com implicações diretas para percepção de complexidade e facilidade de uso.

Task Automation (Automação de Tarefas) refere-se a aplicações de IA que executam tarefas rotineiras, bem-definidas e estruturadas, caracterizadas por regras explícitas e resultados previsíveis. Exemplos incluem automação de e-mails de marketing baseados em gatilhos comportamentais, agendamento automatizado de postagens em redes sociais e geração automática de variações de anúncios para testes A/B (Davenport et al., 2020). *Context Awareness* (Consciência Contextual) engloba aplicações que exigem compreensão de

contexto, adaptação a situações variadas e processamento de sinais múltiplos para decisões não-triviais. Manifestam-se em sistemas de *bidding* inteligente que ajustam lances em tempo real considerando múltiplas variáveis (hora do dia, dispositivo, histórico do usuário), chatbots que interpretam intenções implícitas em linguagem natural e sistemas de recomendação que personalizam conteúdo baseando-se em padrões comportamentais complexos (Davenport et al., 2020). *Decision Support* (Suporte à Decisão) compreende aplicações que fornecem insights, análises preditivas e recomendações para decisões estratégicas, mas mantêm o humano como tomador final de decisão. Incluem ferramentas de análise preditiva de *lifetime value* de clientes, sistemas de otimização de mix de mídia (*Media Mix Modeling* aprimorado por IA) e plataformas de inteligência competitiva que processam fontes diversas para identificar movimentos estratégicos de concorrentes (Davenport et al., 2020).

A conexão dessa taxonomia com Expectativa de Esforço do UTAUT fundamenta-se na premissa de que diferentes tipos de tarefas demandam níveis distintos de investimento em aprendizado, ajuste e interpretação por parte dos usuários:

- **Task Automation → Menor esforço percebido:** ferramentas caracterizadas por interfaces "plug-and-play", requerendo configuração mínima e oferecendo operação relativamente autônoma após setup inicial. A curva de aprendizado é curta e a necessidade de intervenção contínua é baixa (Davenport et al., 2020).

- **Context Awareness → Esforço moderado:** embora mais sofisticadas, essas ferramentas demandam treinamento, ajuste de parâmetros, supervisão periódica e capacidade de interpretar quando a máquina está "confusa" ou produzindo resultados subótimos. Requerem conhecimento técnico intermediário e compreensão dos fundamentos dos

algoritmos.

- **Decision Support → Maior esforço percebido:** além de configuração técnica, exigem capacidade de interpretar outputs complexos, integrá-los com conhecimento tácito de negócio e avaliar criticamente as recomendações geradas. Demandam não apenas competência técnica, mas também sofisticação analítica e experiência de domínio (Davenport et al., 2020).

Para PMEs, caracterizadas por limitações severas de competências técnicas especializadas (Has & Knežević, 2024; Taiminen & Karjaluoto, 2015), essa gradação de complexidade tem implicações diretas para adoção. Evidências empíricas sugerem que PMEs concentram-se predominantemente em aplicações de Task Automation, evitando ferramentas que exigem expertise analítica avançada ou investimento substancial em treinamento (Castanheira et al., 2022). A barreira de "falta de conhecimento em marketing digital" foi identificada como crítica por 46,6% de PMEs europeias, enquanto "dificuldade na criação de conteúdos" afetou 61,6% (Castanheira et al., 2022), sugerindo que percepções de complexidade (Expectativa de Esforço) constituem inibidores significativos de adoção.

Contudo, a emergência de ferramentas de IA generativa baseadas em LLMs pode estar alterando essa dinâmica. Interfaces conversacionais em linguagem natural podem reduzir drasticamente a Expectativa de Esforço mesmo para tarefas de *Context Awareness* ou *Decision Support*, potencialmente democratizando o acesso de PMEs a capacidades analíticas anteriormente restritas a grandes empresas com equipes técnicas especializadas (Davenport et al., 2020). Esta hipótese constitui questão empírica central para a presente investigação.

2.5.4 Integração com Drivers e Barreiras de Adoção em PMEs

Os construtos de Influência Social e Condições Facilitadoras do UTAUT são enriquecidos através da incorporação de evidências empíricas sobre fatores específicos que impulsionam ou obstaculizam a adoção de tecnologias digitais por PMEs. Essa integração ancora o *framework* conceitual em padrões documentados pela literatura contemporânea sobre transformação digital em pequenas e médias empresas.

Quanto aos drivers de adoção (*Social Influence*), a literatura identifica dois mecanismos principais através dos quais pressão externa influencia decisões de gestores de PMEs. Primeiro, a tendência de PMEs adotarem práticas de concorrentes percebidos como bem-sucedidos, especialmente em contextos de incerteza sobre retornos de investimentos tecnológicos. Beynon et al. (2021), em estudo sobre adoção de TICs por PMEs em regiões periféricas do País de Gales, documentaram que percepção de pressão competitiva constituiu fator significativo de adoção: PMEs que percebiam concorrentes utilizando tecnologias digitais apresentaram probabilidade 2,3 vezes maior de adotar essas tecnologias, mesmo quando benefícios tangíveis não eram claramente quantificáveis. Esse padrão sugere que, em mercados onde IA no marketing digital atinge massa crítica de adoção, PMEs retardatárias podem sentir pressão normativa para adotar, independentemente de análise racional de custos-benefícios.

Segundo, a influência de stakeholders externos - fornecedores de tecnologia, consultorias de marketing digital, associações empresariais e instituições de suporte como SEBRAE - desempenha papel crítico na formação de percepções sobre relevância e

viabilidade de novas tecnologias. Esses atores funcionam como "tradutores" que conectam desenvolvimentos tecnológicos abstratos a aplicações práticas compreensíveis para gestores sem formação técnica especializada. Beynon et al. (2021) evidenciaram que investimentos públicos em infraestrutura digital amplificam essa dinâmica: programas governamentais criam legitimidade institucional que reforça mensagens de fornecedores privados, gerando efeito sinérgico sobre percepções de importância da adoção tecnológica.

Quanto às barreiras organizacionais (*Facilitating Conditions*), a literatura converge em três dimensões críticas. As barreiras financeiras incluem não apenas custo direto de ferramentas (licenciamento de software, assinaturas de plataformas), mas também investimentos complementares em infraestrutura tecnológica (hardware adequado, conectividade de internet robusta) e necessidade de alocação de tempo da equipe - recurso escasso em PMEs onde colaboradores frequentemente acumulam múltiplas funções (Has & Knežević, 2024). Estudo com 81 PMEs europeias do setor têxtil identificou "baixo orçamento de marketing" como barreira muito ou extremamente importante para 59,9% das empresas (Castanheira et al., 2022), evidenciando que restrições financeiras limitam experimentação com novas ferramentas.

As barreiras de conhecimento manifestam-se através de múltiplas facetas: lacunas de competências digitais básicas, dificuldade em avaliar qualidade e adequação de ferramentas disponíveis no mercado, incapacidade de traduzir objetivos de negócio em requisitos técnicos e ausência de conhecimento sobre como integrar outputs de IA em processos decisórios existentes. Pesquisa com PMEs brasileiras revelou que "falta de conhecimento em marketing digital" foi considerada barreira muito ou extremamente importante por 46,6% das empresas,

enquanto "dificuldade na criação de conteúdos" afetou 61,6% (Castanheira et al., 2022). Importaneamente, o estudo constatou que "falta de recursos humanos especializados" foi citada por 53,4% como barreira crítica, sugerindo que o problema não é apenas conhecimento do gestor principal, mas capacidade organizacional coletiva (Castanheira et al., 2022).

As barreiras estruturais referem-se a características organizacionais que dificultam adoção efetiva mesmo quando recursos financeiros e conhecimento estão presentes. Incluem falta de processos formalizados (ausência de dados estruturados dificulta treinamento de modelos de IA e mensuração de resultados), cultura organizacional avessa a riscos (especialmente comum em PMEs familiares tradicionais) e resistência à mudança por parte de colaboradores que temem substituição tecnológica. Entretanto, evidências sugerem que resistência gerencial não constitui barreira primária: apenas 35% de PMEs consideraram "resistência da administração" relevante, e apenas 28,3% citaram "resistência de diretores de marketing" como obstáculo significativo (Castanheira et al., 2022). Esse padrão indica que o problema central são capacidades operacionais, não rejeição estratégica da tecnologia.

No contexto brasileiro e especificamente de Capivari-SP, essas barreiras podem ser amplificadas ou atenuadas por fatores locais. PMEs brasileiras concentram-se em setores tradicionais (comércio, serviços, pequena indústria) com níveis de sofisticação digital heterogêneos (SEBRAE, 2024). Municípios do interior paulista como Capivari apresentam infraestrutura tecnológica inferior a capitais, potencialmente limitando acesso a suporte técnico especializado. Por outro lado, ecossistema de apoio regional - incluindo atuação de SEBRAE, associações comerciais locais e programas municipais de fomento à transformação digital - pode funcionar como Condição Facilitadora, provendo capacitação, subsídios e

legitimação institucional que reduzem barreiras (Beynon et al., 2021).

2.5.5 Framework Conceitual Integrado

A Figura a seguir apresenta o framework conceitual integrado que sintetiza as relações teóricas discutidas nas seções anteriores. O modelo posiciona o UTAUT como estrutura organizadora central, enriquecida por frameworks complementares que operacionalizam e contextualizam cada construto no contexto específico de adoção de IA por PMEs no marketing digital.




Figura 1: Modelo UTAUT para Adoção de IA em Marketing Digital Fonte: Do Autor

O framework integrado opera em três níveis analíticos complementares. No nível individual, examina percepções e crenças de gestores de PMEs sobre ferramentas de IA, operacionalizadas através dos quatro construtos do UTAUT. Gestores avaliam benefícios potenciais (*Performance Expectancy*), facilidade de uso (*Effort Expectancy*), pressões do ambiente externo (*Social Influence*) e disponibilidade de recursos de suporte (*Facilitating Conditions*) e essas avaliações moldam tanto decisões de adoção inicial quanto padrões de uso continuado (Venkatesh et al., 2003).

No nível organizacional, reconhece-se que PMEs não são entidades homogêneas: características como porte (micro, pequena ou média empresa), setor de atuação, maturidade digital prévia e recursos disponíveis funcionam como moderadores que amplificam ou atenuam a influência dos construtos do UTAUT sobre decisões de adoção. Por exemplo, PMEs com maior maturidade digital podem apresentar Expectativa de Esforço mais baixa devido a familiaridade com ferramentas digitais, enquanto microempresas podem ser mais sensíveis a Condições Facilitadoras devido a restrições severas de recursos.

No nível contextual, o framework reconhece que decisões de adoção ocorrem dentro de um ecossistema específico - Capivari-SP e sua região - caracterizado por infraestrutura tecnológica disponível, normas setoriais locais, suporte institucional (SEBRAE, associações comerciais) e momento histórico particular (pós-difusão de IA generativa desde novembro de 2022). Esse contexto influencia simultaneamente todos os construtos do UTAUT: afeta percepção de benefícios (se competidores locais estão obtendo ganhos visíveis com IA), facilidade percebida (disponibilidade de capacitação e suporte técnico local), pressão social (normas setoriais emergentes) e condições facilitadoras (programas públicos de apoio) (Beynon et al., 2021).

Os frameworks complementares operacionalizam e enriquecem os construtos do UTAUT, mas não os substituem. Huang e Rust (2021) fornecem vocabulário para especificar tipos de

benefícios (mecânicos, analíticos, emocionais), permitindo que a análise ultrapasse afirmações genéricas sobre "utilidade" da IA e identifique padrões diferenciados de percepção. Davenport et al. (2020) fornecem gradação de complexidade que permite examinar se PMEs concentram-se em aplicações simples devido a barreiras de esforço percebido ou se conseguem acessar capacidades mais sofisticadas. Beynon et al. (2021) e Has e Knežević (2024) documentam mecanismos específicos de influência social e natureza multifacetada das barreiras, informando interpretação de achados empíricos.

Importa enfatizar que o *framework* não é determinístico, mas interpretativo, coerente com a epistemologia qualitativa adotada. Não se postula que os quatro construtos do UTAUT "causam" adoção em sentido positivista, mas que fornecem lentes analíticas para compreender como gestores de PMEs conferem sentido a tecnologias emergentes e tomam decisões sob incerteza e restrições múltiplas. As relações representadas não são hipóteses a serem testadas estatisticamente, mas pressupostos interpretativos que guiarão a análise qualitativa de narrativas dos gestores entrevistados.

O *framework* permite operacionalizar os três objetivos específicos da pesquisa de forma integrada. O Objetivo Específico 1 - identificar práticas de Marketing Digital estabelecidas e como ferramentas de IA estão sendo integradas - será investigado mapeando ferramentas adotadas segundo as taxonomias de Huang e Rust (2021) e Davenport et al. (2020), identificando padrões de concentração em determinados tipos de inteligência ou níveis de complexidade. O Objetivo Específico 2 - analisar impactos da adoção da IA nas operações de Marketing Digital sob ótica dos gestores - será abordado examinando como gestores percebem benefícios (Performance Expectancy) e desafios (Effort Expectancy), conectando percepções subjetivas com reconfiguração efetiva de práticas. O Objetivo Específico 3 - identificar fatores determinantes na decisão de adoção

de IA à luz do modelo UTAUT - será operacionalizado através da análise sistemática dos quatro construtos e seus moderadores, identificando quais fatores são mais salientes em contextos específicos e como interagem.

O *framework* também orienta contribuições teóricas e práticas da pesquisa. Teoricamente, ao aplicar o UTAUT a tecnologias de IA generativa em PMEs brasileiras, contribui para validação e potencial extensão do modelo em contexto contemporâneo não explorado pela literatura original. Ao integrar UTAUT com taxonomias específicas de IA, propõe operacionalização mais granular de construtos como Performance Expectancy, tradicionalmente tratados de forma agregada. Praticamente, ao identificar padrões de percepções e barreiras específicos de PMEs, o framework fundamenta diagnóstico estruturado que pode informar decisões de gestores (quais tipos de IA priorizar dado perfil da empresa), estratégias de fornecedores de tecnologia (como comunicar benefícios e reduzir percepção de complexidade) e políticas públicas (quais barreiras endereçar prioritariamente através de programas de suporte).

2.5.6 Categorias de Análise Emergentes

Embora o framework conceitual integrado apresentado forneça estrutura robusta para orientar coleta e análise de dados, é fundamental reconhecer que a pesquisa qualitativa demanda abertura para fenômenos não antecipados pelas categorias teóricas a priori. A Análise de Conteúdo combina rigor metodológico com flexibilidade interpretativa, operacionalizando-se através de categorias dedutivas (derivadas do framework teórico) e categorias indutivas (emergentes dos dados empíricos).

As categorias dedutivas - alinhadas aos construtos do UTAUT e taxonomias complementares - orientarão a fase inicial de codificação, permitindo identificação sistemática de

trechos das entrevistas relacionados a *Performance Expectancy*, *Effort Expectancy*, *Social Influence* e *Facilitating Conditions*, bem como classificação de ferramentas de IA mencionadas segundo as tipologias de Huang e Rust (2021) e Davenport et al. (2020). Essa codificação estruturada garante que objetivos de pesquisa sejam endereçados e que achados sejam comparáveis com literatura existente.

Contudo, o processo analítico permanecerá atento a temas recorrentes que não se encaixam confortavelmente nas categorias existentes, sinalizando potenciais categorias emergentes. A literatura sobre IA e ética, por exemplo, sugere que gestores podem expressar preocupações sobre viés algorítmico, privacidade de dados de clientes e autenticidade de conteúdo gerado por IA (Davenport et al., 2020) - dimensões não capturadas nos construtos originais do UTAUT. Aspectos emocionais como medo de substituição tecnológica, entusiasmo com possibilidades transformadoras ou ceticismo sobre "*hype*" em torno de IA podem emergir como temas salientes que influenciam decisões de adoção, complementando construtos racionais do UTAUT. Especificidades setoriais não previstas no framework genérico podem revelar-se críticas: PMEs do comércio varejista podem enfrentar desafios distintos de empresas de serviços profissionais, e essas particularidades podem não ser adequadamente capturadas pelos moderadores contemplados.

O processo analítico será iterativo, alternando entre aplicação de categorias dedutivas e identificação indutiva de padrões emergentes. Após codificação inicial baseada no framework conceitual, realizaremos leitura transversal buscando "dados órfãos" - trechos codificados genericamente ou não codificados que possam sinalizar fenômenos relevantes não contemplados. Esses trechos serão examinados coletivamente para identificar temas recorrentes que justifiquem criação de novas categorias, refinadas através de comparação constante entre casos até atingirem saturação teórica.

Transparência metodológica sobre esse processo será documentada detalhadamente no Capítulo 3 (Metodologia), incluindo protocolos para decisão sobre criação de novas categorias, critérios para saturação e estratégias para garantir que abertura indutiva não comprometa rigor analítico. No Capítulo 4 (Análise dos Resultados), categorias emergentes serão claramente identificadas e sua descoberta será narrada, diferenciando-as analiticamente das categorias dedutivas. Na Discussão (Capítulo 5), categorias emergentes serão confrontadas com literatura adicional não contemplada no referencial teórico inicial, explorando se representam lacunas na literatura existente, especificidades contextuais ou artefatos metodológicos.

Essa postura epistemológica - estruturação sem rigidez, teoria sem camisa de força - alinha-se com pressupostos da pesquisa qualitativa interpretativa e maximiza potencial da investigação para gerar insights genuinamente novos além de validar conhecimento estabelecido. Reconhece-se que a realidade das PMEs de Capivari-SP utilizando IA no marketing digital pós-2022 pode apresentar facetas não capturadas por frameworks desenvolvidos antes da difusão de IA generativa e testados predominantemente em contextos de grandes empresas de economias desenvolvidas.

2.5.6 Síntese do Framework conceitual

Este capítulo apresentou a fundamentação teórica que ancora a presente investigação, organizando-a em torno de três eixos complementares: o Modelo UTAUT como framework explicativo da adoção tecnológica, taxonomias de Inteligência Artificial que operacionalizam tipos de benefícios e níveis de complexidade, e evidências empíricas sobre especificidades de PMEs que contextualizam barreiras e drivers de adoção.

O framework conceitual integrado proposto constitui síntese original que articula esses

corpos teóricos em modelo analítico coerente, capaz de orientar investigação empírica sistemática ao mesmo tempo que permanece aberto a descobertas indutivas. Equilibra estruturação teórica (garantindo alinhamento com objetivos de pesquisa e comparabilidade com literatura) e flexibilidade metodológica (permitindo captura de fenômenos emergentes específicos do contexto contemporâneo de IA generativa em PMEs brasileiras).

A operacionalização desse framework conceitual em estratégia metodológica concreta - incluindo definição de unidades de análise, protocolos de coleta de dados, roteiro de entrevistas estruturado segundo construtos do UTAUT, e procedimentos de análise de conteúdo - será detalhada no próximo capítulo. Os construtos teóricos aqui estabelecidos guiarão a elaboração de questões de entrevista que darão ensejo a narrativas ricas dos gestores, enquanto as taxonomias de IA fornecerão esquemas de codificação que permitirão análise sistemática dessas narrativas. O resultado esperado é investigação empiricamente fundamentada, teoricamente informada e metodologicamente rigorosa sobre fenômeno contemporâneo de alta relevância tanto acadêmica quanto gerencial.

3 METODOLOGIA

3.1 Caracterização da Pesquisa

Esta pesquisa caracteriza-se metodologicamente segundo múltiplas dimensões que refletem a natureza do problema investigado, os objetivos estabelecidos e as especificidades do fenômeno estudado. A seguir, detalham-se as classificações quanto à natureza, abordagem, objetivos, procedimentos técnicos e recorte temporal.

3.1.1 Pesquisa Aplicada

Esta investigação classifica-se como pesquisa aplicada, pois visa gerar conhecimento com aplicação prática direcionada à solução de problemas concretos enfrentados por Micro, Pequenas e Médias Empresas (PMEs) brasileiras no contexto da transformação digital. Diferencia-se, assim, da pesquisa básica — que busca conhecimento puro sem aplicação imediata — pela orientação explícita para contribuir com a prática gerencial e a formulação de políticas públicas.

Os achados desta pesquisa destinam-se a três públicos específicos: gestores de PMEs que necessitam tomar decisões informadas sobre investimento e integração de ferramentas de Inteligência Artificial (IA) em suas estratégias de marketing digital; instituições de apoio como o SEBRAE que desenham programas de capacitação e fomento à transformação digital; e desenvolvedores de tecnologia que buscam compreender expectativas, dificuldades e requisitos específicos desse segmento de mercado. A caracterização como pesquisa aplicada alinha-se aos objetivos específicos estabelecidos — particularmente o OE2, que busca analisar impactos percebidos da adoção de IA e seu papel na mitigação de obstáculos tradicionais das PMEs, e o OE3, que visa identificar fatores determinantes de adoção para subsidiar decisões práticas.

3.1.2. Abordagem Qualitativa Interpretativa

A pesquisa adota abordagem qualitativa, pois privilegia a compreensão profunda de significados, percepções e experiências dos gestores de PMEs sobre o fenômeno da adoção de IA no marketing digital. Fenômenos sociais complexos — como processos de aceitação e uso de tecnologias emergentes em contextos organizacionais de recursos limitados — não podem ser adequadamente capturados apenas por variáveis numéricas ou métricas de desempenho,

demandando análise interpretativa de narrativas e construção de sentido a partir das experiências vividas pelos sujeitos.

A postura epistemológica adotada é interpretativa: os dados não "falam por si", mas são construídos pela interação entre pesquisador, participantes e contexto. Reconhece-se que a realidade investigada — gestores de PMEs conferindo sentido a ferramentas de IA generativa em suas práticas de marketing — é socialmente construída e contextualmente situada. Esta postura contrasta com abordagens positivistas que postulam a existência de uma realidade objetiva, externa e mensurável, acessível através de instrumentos padronizados.

A escolha pela abordagem qualitativa justifica-se por três razões fundamentais. Primeiro, o problema de pesquisa orienta-se por questões do tipo "como" e "por que" — especificamente, *como* a IA reconfigura práticas de marketing digital e *por que* alguns gestores adotam essas tecnologias enquanto outros não — que são caracteristicamente respondidas por pesquisas qualitativas.

Segundo, a literatura documenta lacuna empírica sobre adoção de IA generativa por PMEs em países em desenvolvimento, configurando fenômeno ainda não suficientemente mapeado, contexto no qual a abordagem qualitativa é particularmente apropriada para capturar nuances e gerar categorias analíticas emergentes.

Terceiro, a aplicação do Modelo Unificado de Aceitação e Uso de Tecnologia (UTAUT) em contexto inédito — ferramentas de IA generativa pós-2022 em PMEs brasileiras — demanda investigação em profundidade que permita não apenas testar construtos teóricos, mas identificar eventuais construtos emergentes específicos deste contexto.

Cabe diferenciar esta escolha metodológica de abordagem quantitativa. Pesquisas quantitativas buscam a generalização estatística via amostras representativas, testando hipóteses sobre relações entre variáveis através de procedimentos padronizados de mensuração. A pesquisa qualitativa, por sua vez, busca transferibilidade — não generalização — oferecendo descrição densa que permite leitores avaliarem aplicabilidade dos achados a outros contextos similares. Enquanto a abordagem quantitativa seria apropriada para testar, por exemplo, a força preditiva dos construtos do UTAUT em uma amostra probabilística nacional de PMEs, a abordagem qualitativa é mais adequada para compreender *como* esses construtos se manifestam concretamente em contextos específicos e *por que* determinados fatores emergem como mais salientes.

3.1.3 Exploratória-Descritiva

Quanto aos objetivos, a pesquisa caracteriza-se como exploratória-descritiva, combinando duas dimensões complementares que refletem o estágio de conhecimento sobre o fenômeno investigado e os propósitos da investigação.

A dimensão exploratória justifica-se pela natureza recente e pouco documentada do fenômeno investigado. A difusão massiva de ferramentas de IA generativa iniciou-se apenas em novembro de 2022, com o lançamento do ChatGPT, configurando ruptura tecnológica sem precedentes pela acessibilidade, baixo custo e operabilidade por usuários sem conhecimento técnico profundo. Pesquisas exploratórias são apropriadas quando se busca familiarização com problema ainda não suficientemente mapeado, permitindo construção de hipóteses para investigações futuras e identificação de variáveis relevantes.

A lacuna na literatura acadêmica justifica inequivocamente a abordagem exploratória. Davenport et al. (2020), em agenda de pesquisa publicada no *Journal of the Academy of Marketing Science*, reconhecem explicitamente a ausência de estudos empíricos sobre adoção de IA em diferentes tipos de organizações, particularmente em PMEs. Thaha et al. (2021), em revisão sistemática sobre marketing digital em pequenas empresas, identificam necessidade urgente de investigações em contextos geográficos específicos de países em desenvolvimento. Has e Knežević (2024), ao mapear tendências de pesquisa sobre digitalização de PMEs, documentam que a IA generativa não aparece como *trending topic* em suas análises bibliométricas até 2022, evidenciando a janela temporal que este estudo pretende capturar.

A dimensão descritiva justifica-se pelo objetivo de caracterizar práticas atuais de marketing digital nas PMEs investigadas, descrevendo como a IA está sendo integrada a essas práticas. Pesquisas descritivas objetivam a descrição de determinada população, fenômeno ou estabelecimento de relações entre variáveis, diferenciando-se de pesquisas meramente exploratórias pela existência de base teórica prévia que orienta a descrição. O Objetivo Específico 1 (OE1) — identificar práticas e ferramentas de Marketing Digital estabelecidas antes e após a difusão da IA generativa — possui caráter inequivocamente descritivo, buscando mapear o estado atual do fenômeno.

A classificação como exploratória-descritiva é comum e apropriada quando se investigam fenômenos contemporâneos ainda não plenamente mapeados, mas sobre os quais já existe base teórica consolidada que orienta a investigação. Neste estudo, embora o fenômeno específico — adoção de IA generativa por PMEs — seja recente e pouco documentado (dimensão exploratória), a investigação ancora-se no framework teórico robusto do UTAUT e em taxonomias de IA aplicadas

ao marketing (dimensão descritiva orientada por teoria). Esta combinação permite simultaneamente explorar um território empírico novo e descrever sistematicamente suas características segundo categorias analíticas teoricamente fundamentadas.

3.1.4. Estudo de Caso Múltiplo

Quanto aos procedimentos técnicos, a pesquisa adota a estratégia de estudo de caso múltiplo.

Segundo Yin (2015, p. 17), estudo de caso constitui "investigação empírica que investiga um fenômeno contemporâneo (o 'caso') em profundidade e em seu contexto de mundo real, especialmente quando os limites entre o fenômeno e o contexto puderem não ser claramente evidentes".

Esta estratégia mostra-se particularmente apropriada quando: a) As questões de pesquisa orientam-se por "como" e "por que"/ b) O pesquisador tem pouco controle sobre eventos comportamentais e c) O foco recai sobre fenômeno contemporâneo em contexto real

A escolha por casos múltiplos (em contraposição a caso único) fundamenta-se na necessidade de capturar variabilidade contextual entre PMEs de diferentes portes, setores e estágios de adoção de IA, permitindo identificação de padrões convergentes e divergentes que fortalecem a robustez analítica dos achados.

O detalhamento da lógica de replicação, critérios de seleção, número de casos e protocolos de coleta/análise será apresentado nas seções subsequentes deste capítulo.

3.1.5. Transversal com Perspectiva Retrospectiva

Quanto ao recorte temporal, a pesquisa caracteriza-se como transversal com perspectiva retrospectiva. Pesquisa transversal implica que a coleta de dados ocorre em momento único — especificamente, no período de outubro a dezembro de 2025 — diferenciando-se de pesquisas longitudinais que acompanham os mesmos sujeitos ao longo do tempo.

Contudo, embora a coleta seja pontual, as entrevistas semiestruturadas incorporam dimensão retrospectiva, capturando percepções dos gestores sobre práticas "antes" e "depois" da difusão das ferramentas de IA generativa. O marco temporal de referência é novembro de 2022 — lançamento do ChatGPT — que representa ruptura tecnológica documentada na literatura como momento de democratização do acesso à IA generativa. As questões norteadoras, particularmente QN1 e QN3, solicitam explicitamente que gestores reflitam sobre mudanças nas práticas de marketing digital, benefícios percebidos e desafios enfrentados desde a disponibilização dessas ferramentas.

Esta abordagem transversal com perspectiva retrospectiva justifica-se por duas razões. Primeiro, investigações longitudinais que acompanhassem as mesmas PMEs desde 2022 até 2025 seriam ideais do ponto de vista metodológico, mas inviáveis dado o cronograma de um trabalho de mestrado e a necessidade de capturar o fenômeno enquanto ainda está em estágio inicial de difusão. Segundo, a memória recente dos gestores sobre o período pré-IA (menos de três anos) permite reconstrução narrativa confiável das transformações ocorridas, particularmente porque a adoção de ferramentas digitais tende a ser um evento marcante na rotina de pequenas empresas.

Reconhece-se, contudo, a limitação inerente a este recorte temporal: dados retrospectivos estão sujeitos a vieses de memória e racionalização *post-hoc*. Gestores podem, inconscientemente,

reinterpretar práticas passadas à luz de experiências atuais ou exagerar a magnitude das mudanças ocorridas. Para mitigar esta limitação, o roteiro de entrevistas solicitará exemplos concretos e específicos de práticas antes e depois da adoção de IA, buscando ancoragem factual às narrativas retrospectivas.

3.1.5. Síntese Metodológica

O Quadro 2 sintetiza as classificações metodológicas estabelecidas, evidenciando a coerência interna entre as múltiplas dimensões da caracterização da pesquisa.19-01-25.docx

Quadro 2

Síntese da Caracterização Metodológica da Pesquisa

Dimensão	Classificação	Justificativa Sintética
Metodológica		
Natureza	Aplicada	Gera conhecimento para solução de problemas práticos de PMEs; subsidia gestores, formuladores de políticas públicas e desenvolvedores de tecnologia
Abordagem	Qualitativa interpretativa	Privilegia compreensão de significados, percepções e experiências dos gestores; fenômeno socialmente construído demanda análise interpretativa de narrativas

Objetivos	Exploratória-des critiva	Fenômeno recente (IA generativa pós-2022) demanda exploração; base teórica consolidada (UTAUT) orienta descrição sistemática de práticas atuais
Procedimentos	Estudo de caso múltiplo	Investiga fenômeno contemporâneo em contexto real; casos múltiplos permitem replicação lógica e captura de variações contextuais, fortalecendo robustez analítica
Recorte temporal	Transversal com perspectiva retrospectiva	Coleta única (out-dez/2025) captura percepções sobre evolução temporal desde marco de nov/2022; viabiliza investigação oportuna de fenômeno em estágio inicial de difusão

Nota. PMEs = Micro, Pequenas e Médias Empresas; IA = Inteligência Artificial; UTAUT = Unified Theory of Acceptance and Use of Technology (Modelo Unificado de Aceitação e Uso de Tecnologia).

3.2 Estratégia de Pesquisa: Estudo de Caso Múltiplo

Definida a natureza qualitativa interpretativa e exploratório-descritiva da investigação (seção 3.1), torna-se imperativo especificar a estratégia metodológica que operacionalizará a coleta e análise de dados empíricos. Esta seção detalha a lógica de replicação que fundamenta o estudo de caso múltiplo, a definição precisa da unidade de análise, os critérios de seleção intencional das PMEs participantes e a articulação entre objetivos específicos e configuração de casos. O propósito é demonstrar rigor metodológico na operacionalização do framework conceitual integrado apresentado no Capítulo 2 (seção 2.5), assegurando que a estratégia empírica seja capaz de responder às questões norteadoras e contribuir tanto para o avanço teórico quanto para recomendações práticas.

3.2.1. Lógica de Replicação como Fundamento Metodológico

O estudo de caso múltiplo distingue-se radicalmente de desenhos de pesquisa baseados em lógica de amostragem estatística. Conforme enfatizado por Yin (2015, p. 60), "a lógica subjacente ao uso de estudos de casos múltiplos é a mesma [dos experimentos múltiplos]. Cada caso deve ser selecionado cuidadosamente para que: (a) possa prever resultados similares (uma replicação literal); ou (b) possa produzir resultados contrastantes, mas para razões previsíveis (uma replicação teórica)". Esta distinção epistemológica é fundamental: casos não constituem "amostra representativa" de uma população sobre a qual se pretende generalizar estatisticamente, mas sim replicações experimentais que testam e refinam proposições teóricas através de generalização analítica (Yin, 2015).

A generalização analítica, objetivo primordial do estudo de caso, consiste em extrair insights teóricos que possam ser transferidos a contextos com características similares, não em estimar parâmetros populacionais. Como explica Yin (2015, p. 40), "você está tentando generalizar um conjunto particular de resultados para alguma teoria mais ampla". No contexto desta pesquisa, a teoria mais ampla é o framework conceitual integrado (seção 2.5), que articula o Modelo UTAUT (Venkatesh et al., 2003) às taxonomias de IA aplicadas ao marketing (Huang & Rust, 2021; Davenport et al., 2020) e às especificidades de PMEs brasileiras (SEBRAE & FGV, 2024). Os casos serão teoricamente selecionados para testar se — e como — os construtos desse framework se manifestam concretamente quando gestores de PMEs de Capivari-SP adotam ferramentas de IA generativa no marketing digital pós-2022.

As implicações metodológicas desta lógica são profundas. Primeiro, a validade externa dos achados não depende de representatividade estatística, mas da robustez teórica das proposições testadas e refinadas através de múltiplos casos (Yin, 2015). Segundo, a seleção de casos deve ser intencional (*purposeful sampling*), guiada por critérios teóricos que maximizem oportunidades de aprendizado sobre o fenômeno investigado, não aleatória (Patton, 2015). Terceiro, o número de casos é determinado por considerações de saturação teórica e suficiência analítica, não por cálculos de poder estatístico (Eisenhardt, 1989).

A articulação desta lógica com os objetivos específicos da pesquisa é direta. O Objetivo Específico 1 — identificar práticas de Marketing Digital e como a IA está sendo integrada — demanda captura de variabilidade contextual entre PMEs de diferentes portes, setores e estágios de adoção. Apenas através de casos múltiplos é possível mapear essa diversidade e identificar padrões robustos versus práticas idiossincráticas. O Objetivo Específico 2 — analisar impactos percebidos

da adoção de IA — beneficia-se da comparação entre percepções de diferentes gestores, fortalecendo a validade das categorias analíticas emergentes através de triangulação entre casos (Yin, 2015). O Objetivo Específico 3 — identificar fatores determinantes de adoção segundo o modelo UTAUT — requer testagem dos construtos teóricos em contexto inédito (IA generativa pós-2022 em PMEs brasileiras), o que se operacionaliza através da busca por padrões convergentes (replicação literal) e divergências teoricamente previsíveis (replicação teórica) entre casos cuidadosamente selecionados.

Esta estratégia alinha-se à epistemologia qualitativa interpretativa adotada (seção 3.1.2), pois reconhece que a adoção de tecnologia é fenômeno socialmente construído, influenciado por percepções subjetivas de gestores, contextos organizacionais específicos e dinâmicas locais. Ao invés de buscar "verdades universais" através de testes estatísticos, o estudo de caso múltiplo permite compreensão profunda e contextualizada de como e por que gestores de PMEs conferem sentido a ferramentas de IA, tomam decisões sob incerteza e reconfiguram — ou não — suas práticas de marketing digital.

3.2.2. Replicação Literal: Identificação de Padrões Convergentes

Definida a lógica geral de replicação (seção 3.2.1), operacionaliza-se agora sua primeira aplicação: a replicação literal. Segundo Yin (2015, p. 60-61), replicação literal consiste em selecionar casos com condições contextuais similares, para os quais se prevê resultados convergentes com base em proposições teóricas. A lógica é análoga à de experimentos laboratoriais: se a teoria estiver correta, casos comparáveis devem produzir padrões semelhantes de comportamento, atitudes e resultados.

No contexto desta pesquisa, a replicação literal será operacionalizada através da seleção de três PMEs com características comparáveis: pequeno porte (10-49 funcionários segundo critérios SEBRAE), atuantes no mesmo setor econômico (por exemplo, comércio varejista de Capivari-SP), classificadas como adotantes ativas de ferramentas de IA generativa no marketing digital (uso regular há pelo menos três meses) e com nível de maturidade digital prévia similar (presença consolidada em redes sociais, site institucional, histórico de publicidade digital).

A previsão teórica associada a esta configuração é que gestores dessas três PMEs devam relatar:

1. **Convergência no tipo de ferramentas adotadas:** Uso predominante de LLMs acessíveis (ChatGPT, Google Gemini, Claude) para criação de conteúdo textual (posts para redes sociais, legendas, descrições de produtos) e geradores de imagens baseados em IA (DALL-E, Midjourney, ferramentas nacionais como NanoBanana) para assets visuais — correspondendo à Mechanical AI e Thinking AI de Huang e Rust (2021), com foco em automação de tarefas criativas e personalização de conteúdo.
2. **Convergência nos benefícios percebidos (*Performance Expectancy*):** Ganhos em eficiência operacional (redução de tempo para criação de conteúdo), economia de custos (substituição parcial de serviços terceirizados de design/redação) e aumento de volume de publicações — alinhados à dimensão de padronização e personalização das taxonomias de IA (Huang & Rust, 2021).
3. **Convergência nas barreiras enfrentadas (*Effort Expectancy*):** Dificuldade inicial na elaboração de *prompts* eficazes, necessidade de curadoria humana para evitar erros factuais ou linguagem inadequada à marca, e curva de aprendizado para integração da IA aos

workflows existentes — desafios típicos de Context Awareness na taxonomia de Davenport et al. (2020), onde a tecnologia exige adaptação contextual.

4. **Convergência na ausência ou limitação de uso de IA Sentimental (*Feeling AI*):** Baixa adoção de chatbots avançados com processamento de linguagem natural para atendimento ao cliente, possivelmente devido a percepções de complexidade técnica elevada ou medo de experiências negativas com clientes — alinhado aos desafios de "imaturidade tecnológica" e "não prontidão do cliente" discutidos por Huang e Rust (2021, p. 40).

A contribuição analítica da replicação literal reside em dois aspectos. Primeiro, padrões que se repetem em três casos independentes com condições similares fortalecem a validade interna das proposições: demonstram que os achados não são idiossincráticos de um único caso, mas representam fenômeno replicável (Yin, 2015). Segundo, a identificação de práticas convergentes permite a construção de "perfis-tipo" de adoção — por exemplo, "o perfil do pequeno varejista adotante de IA" — que possuem utilidade tanto teórica (refinamento de categorias de análise) quanto prática (benchmark para gestores em posição similar avaliarem suas próprias estratégias).

Importante ressaltar que "convergência" não implica identidade absoluta. Variações menores são esperadas e analiticamente valiosas, pois revelam nuances contextuais. O critério de convergência é a presença de padrões nucleares comuns — por exemplo, todos os três casos utilizam LLMs para criação de conteúdo, embora possam diferir na frequência de uso ou nas ferramentas específicas preferidas. A análise buscará tanto os denominadores comuns quanto as variações sutis, enriquecendo a compreensão do fenômeno.

3.2.3. Replicação Teórica: Captura de Variações Contrastantes

Complementando a replicação literal, a replicação teórica operacionaliza a seleção de casos com condições contextuais deliberadamente diferentes, para os quais se prevê resultados contrastantes por razões teoricamente fundamentadas (Yin, 2015, p. 61-62). Esta estratégia é essencial para testar os limites e moderadores do framework conceitual integrado: sob quais condições os construtos do UTAUT se manifestam de forma distinta? Quais características organizacionais amplificam ou atenuam a influência da *Performance Expectancy* ou das *Facilitating Conditions* sobre decisões de adoção?

A replicação teórica será operacionalizada através de três tipos de contraste intencional, cada um fundamentado em proposições teóricas específicas:

Contraste 1: Estágio de Adoção (Adotantes vs. Não-Adotantes)

Configuração: Contrastar as três PMEs adotantes ativas (replicação literal) com duas PMEs não-adotantes — isto é, empresas que conhecem a existência de ferramentas de IA generativa, mas optaram por não adotá-las no marketing digital até o momento da coleta de dados.

Previsão teórica baseada no UTAUT (Venkatesh et al., 2003):

- *Performance Expectancy* baixa: Não-adotantes tenderão a expressar ceticismo sobre benefícios reais da IA ("não vejo como isso ajudaria meu negócio"), desconfiança sobre qualidade dos outputs ("conteúdo genérico, sem personalidade da marca") ou percepção de que custos (tempo de aprendizado, riscos de erros) superam benefícios — contrastando com as percepções positivas de adotantes.

- Facilitating Conditions precárias: Relatarão falta de capacitação acessível sobre como usar IA, ausência de suporte técnico local, receios sobre conformidade com LGPD (Lei Geral de Proteção de Dados) ao processar dados de clientes em plataformas de IA, ou limitações de conectividade/infraestrutura tecnológica — barreiras amplamente documentadas na literatura sobre PMEs (Has & Knežević, 2024; SEBRAE, 2024).
- Social Influence negativa ou neutra: Ausência de pressão competitiva percebida ("meus concorrentes também não usam"), falta de modelos de referência exitosos no setor/localidade, ou normas culturais de resistência a automação ("prefiro o toque humano na comunicação") — contrastando com possível pressão normativa entre adotantes.

Contribuição analítica: Este contraste permite triangular os fatores determinantes de adoção. Se adotantes e não-adotantes diferirem sistematicamente em suas percepções de Performance Expectancy e Facilitating Conditions, mas não em Social Influence, isso sugere que os dois primeiros construtos são mais salientes no contexto investigado — informando tanto teoria (refinamento do modelo UTAUT) quanto prática (onde concentrar intervenções de apoio).

Contraste 2: Porte Organizacional (Microempresas vs. Médias Empresas)

Configuração: Contrastar as três pequenas empresas (replicação literal) com uma microempresa (< 10 funcionários) e uma média empresa (50-249 funcionários), ambas adotantes de IA.

Previsão teórica baseada em literatura sobre PMEs (Has & Knežević, 2024; SEBRAE & FGV, 2024):

- Microempresa:

- *Effort Expectancy* mais elevada devido a recursos humanos extremamente limitados (frequentemente apenas o proprietário-gestor executando múltiplas funções), menor familiaridade com ferramentas digitais complexas e ausência de suporte técnico interno.
- Concentração em aplicações de Mechanical AI (automação simples) e uso limitado de Thinking AI (análise preditiva, personalização sofisticada), devido a barreiras de competência técnica.
- *Facilitating Conditions* mais frágeis: menor capacidade de investimento em planos pagos de ferramentas de IA, conectividade de internet potencialmente instável, ausência de políticas formais de proteção de dados.
- Média empresa:
 - *Facilitating Conditions* mais robustas: equipe de marketing estruturada (ainda que pequena), maior capacidade de investimento em ferramentas e capacitação, processos mais formalizados.
 - Uso mais diversificado de IA: além de Mechanical AI, incorporação de Thinking AI para análise de dados de CRM, segmentação avançada de audiências e otimização de campanhas de mídia paga — e possivelmente experimentação com Feeling AI (chatbots com NLP para atendimento).
 - *Effort Expectancy* potencialmente mais baixa devido a maior capacidade absorviva organizacional (Cohen & Levinthal, 1990) — equipe com maior escolaridade e experiência prévia com tecnologias digitais.

Contribuição analítica: Este contraste testa o porte como moderador dos construtos do UTAUT, proposição central na literatura sobre adoção de tecnologia em PMEs (Abdat, 2020). Se microempresas concentrarem-se em aplicações simples (Mechanical AI) enquanto médias empresas acessam capacidades avançadas (Thinking AI), isso valida a hipótese de que *Facilitating Conditions* e *Effort Expectancy* variam sistematicamente com recursos organizacionais — com implicações diretas para políticas de apoio segmentadas por porte.

Contraste 3: Setor de Atuação (Comércio vs. Serviços vs. Indústria)

Configuração: Contrastar as três PMEs do comércio varejista (replicação literal) com uma PME de serviços profissionais (exemplo: escritório de contabilidade, agência de turismo, consultoria) e uma PME industrial (exemplo: indústria têxtil, metalúrgica, agroindústria).

Previsão teórica baseada em literatura setorial (Castanheira et al., 2022; Thaha et al., 2021):

- Setor de serviços:
 - Maior uso de IA para personalização de relacionamento e comunicação consultiva: chatbots para agendamento de consultas, IA para análise de feedback de clientes, geração de conteúdo educacional (artigos de blog, newsletters) que posicionem a empresa como autoridade.
 - Ênfase em Feeling AI (análise de sentimento, empatia simulada) devido à natureza relacional do negócio — contrastando com foco em eficiência do comércio.
- Setor industrial:

- Uso de IA mais concentrado em otimização de processos do que em comunicação de marketing: previsão de demanda (Thinking AI), automação de relatórios de produção (Mechanical AI).
- Marketing digital potencialmente menos sofisticado (foco em marketing B2B através de representantes comerciais, não em presença digital orgânica), resultando em menor adoção de ferramentas generativas de conteúdo — mas possível uso de IA para análise de tendências de mercado e inteligência competitiva.

Contribuição analítica: Este contraste explora como normas setoriais e natureza da atividade econômica moderam a saliência dos construtos UTAUT. Se PMEs de serviços priorizarem Feeling AI (relacionamento) enquanto industriais priorizarem Thinking AI (otimização), isso demonstra que *Performance Expectancy* não é construto homogêneo — diferentes setores valorizam diferentes tipos de benefícios, informando estratégias de comunicação diferenciadas por parte de fornecedores de tecnologia.

Configuração Final Proposta

Integrando replicações literais e teóricas, a configuração final proposta compreende 7-8 PMEs:

- 3 casos de replicação literal: Pequenas empresas, setor comercial, adotantes ativas, maturidade digital similar.
- 2 casos de replicação teórica (Contraste 1): Pequenas empresas, setor comercial, não-adotantes.

- 2 casos de replicação teórica (Contraste 2): 1 microempresa + 1 média empresa, ambas adotantes.
- 1-2 casos de replicação teórica (Contraste 3): 1 PME de serviços + 1 PME industrial (opcional, se viabilidade de acesso permitir).

Esta configuração assegura suficiência analítica para responder aos objetivos específicos, mantendo viabilidade operacional dentro dos recursos e prazos de um mestrado. Yin (2015, p. 63) sugere que "você talvez queira estabelecer duas ou três replicações literais quando sua teoria for simples", mas adverte que "se sua teoria for sutil ou se você desejar um alto grau de certeza, pode exigir cinco, seis ou mais replicações". Dado que o framework conceitual integrado é teoricamente robusto (UTAUT validado em múltiplos contextos), mas o fenômeno empírico (IA generativa pós-2022 em PMEs brasileiras) é inexplorado, a configuração de 7-8 casos equilibra ambição analítica e viabilidade prática.

3.2.4. Unidade de Análise e Delimitação Temporal dos Casos

A definição precisa da unidade de análise é requisito metodológico fundamental em estudos de caso, pois determina o que constitui "um caso" e estabelece as fronteiras do fenômeno investigado (Yin, 2015, p. 47-49). Nesta pesquisa, a unidade de análise é definida como:

A PME de Capivari-SP como organização, com foco nas percepções e experiências do gestor/tomador de decisão sobre adoção e uso de ferramentas de IA generativa no marketing digital.

Esta definição possui três componentes interdependentes. Primeiro, a PME como organização estabelece que o caso não é o gestor individual isoladamente, mas a empresa enquanto entidade que adota (ou não) tecnologias. Características organizacionais — porte, setor, maturidade digital, recursos disponíveis — são atributos do caso, não do informante. Segundo, o foco nas percepções e experiências do gestor reconhece que, em PMEs, decisões sobre adoção de tecnologia são frequentemente centralizadas no proprietário ou gestor principal, cuja interpretação subjetiva do valor, da complexidade e das pressões ambientais determina as escolhas estratégicas (Abdat, 2020). Terceiro, a delimitação a ferramentas de IA generativa no marketing digital especifica o domínio empírico, excluindo outras aplicações de IA (como sistemas de gestão de estoques ou automação industrial) que, embora relevantes, não respondem ao problema de pesquisa.

As fronteiras organizacionais são demarcadas da seguinte forma:

- Incluído: Práticas, decisões, percepções e resultados relacionados ao marketing digital sob responsabilidade ou conhecimento do gestor entrevistado — abrangendo gestão de redes sociais, criação de conteúdo, publicidade digital, relacionamento com clientes online, análise de métricas digitais e uso de ferramentas de IA nesses processos.
- Excluído: Práticas de outras áreas organizacionais (produção, logística, finanças, recursos humanos) que não interfiram diretamente no marketing digital; aplicações de IA fora do escopo de marketing (por exemplo, automação contábil); e tecnologias digitais que não envolvam IA (como simples agendadores de postagens sem recursos de geração ou análise inteligente).

A delimitação temporal ancora-se em marco histórico específico, já estabelecido na seção 3.1.5 (Recorte Temporal):

- Marco inicial: Novembro de 2022 — mês de lançamento do ChatGPT pela OpenAI, evento que simboliza a difusão massiva de ferramentas de IA generativa acessíveis ao público geral e a PMEs sem expertise técnica prévia (Kanezaki et al., 2024).
- Marco final: Momento da coleta de dados (previsto para [especificar trimestre/ano, por exemplo: primeiro trimestre de 2026]).
- Justificativa: Este período captura a janela crítica de experimentação inicial, formação de percepções primárias e decisões de adoção ou não-adoção de ferramentas de IA generativa por PMEs. É um período suficientemente longo (aproximadamente 3 anos) para permitir que gestores desenvolvam experiências substantivas com a tecnologia, mas suficientemente recente para que memórias sobre motivações, desafios e impactos permaneçam vívidas e detalhadas — condição essencial para coleta de dados qualitativos ricos (Eisenhardt & Graebner, 2007).

Quanto ao tipo de projeto de estudo de caso, Yin (2015, p. 58-59) distingue entre projetos holísticos (caso tratado como unidade única) e integrados (com subunidades de análise formalizadas). Esta pesquisa adota projeto holístico: cada PME é tratada como totalidade contextual, não sendo decomposta em subunidades analíticas formais (por exemplo, "departamento de marketing" vs. "departamento de vendas", pois PMEs frequentemente não possuem tal diferenciação; ou "uso de ChatGPT" vs. "uso de Gemini", pois ferramentas são evidências, não subunidades).

A razão para a escolha holística alinha-se aos objetivos da pesquisa: compreender como a IA reconfigura práticas de marketing digital na PME como um todo, considerando interdependências entre decisões, percepções, recursos e contexto. Embora dados específicos sobre ferramentas

individuais (ChatGPT, DALL-E) sejam coletados e analisados, essas ferramentas são tratadas como manifestações das inteligências de IA (Mechanical, Thinking, Feeling) discutidas no Capítulo 2, não como unidades de análise independentes. A análise cruzada de casos (seção 3.5) integrará essas manifestações em padrões mais amplos de adoção, alinhados aos construtos do UTAUT.

3.2.5. Critérios de Seleção Intencional e Número de Casos

A operacionalização das replicações literal e teórica (seções 3.2.2 e 3.2.3) exige a tradução de construtos abstratos em procedimentos concretos de triagem e seleção de PMEs participantes. Esta seção explicita os critérios de inclusão, os critérios de diversidade intencional e os procedimentos operacionais que assegurarão a coerência entre estratégia teórica e execução empírica.

Justificativa do Número de Casos

Conforme antecipado, a pesquisa propõe 7-8 PMEs como configuração final. Este número não deriva de cálculo amostral estatístico, mas de consideração discricionária baseada em três fatores:

1. Orientação metodológica de Yin (2015): "Designar o número de replicações depende da certeza que você deseja ter sobre os resultados dos casos múltiplos [...]. Você talvez queira estabelecer duas ou três replicações literais quando sua teoria for simples [...]. No entanto, se sua teoria for sutil ou se você desejar um alto grau de certeza, pode exigir cinco, seis ou mais replicações" (Yin, 2015, p. 63-65).
2. Complexidade do framework conceitual: O modelo UTAUT é teoricamente robusto e empiricamente validado (Venkatesh et al., 2003), mas sua aplicação a IA generativa

pós-2022 em PMEs brasileiras constitui contexto empírico inexplorado. A integração com taxonomias de IA (Huang & Rust, 2021; Davenport et al., 2020) adiciona camadas de complexidade analítica. Portanto, um número maior de casos (7-8) é justificável para capturar variabilidade suficiente e alcançar saturação teórica razoável (Guest et al., 2006).

3. Viabilidade operacional: Estudos de caso em profundidade demandam recursos substanciais de tempo (entrevistas de 60-90 minutos, transcrições, análise de documentos complementares, análise individual e cruzada). A configuração de 7-8 casos é compatível com os recursos e prazos típicos de um mestrado profissional, assegurando qualidade analítica sem comprometer viabilidade.

CrITÉRIOS de Inclusão (Obrigatórios para Todos os Casos)

Para ser elegível à participação, uma PME deve atender cumulativamente aos seguintes critérios:

1. Localização geográfica: Sede principal ou filial operacional no município de Capivari-SP, coerente com a delimitação do problema de pesquisa (seção 1.2).
2. Classificação como PME: Enquadramento como microempresa, pequena empresa ou média empresa segundo critérios do SEBRAE (por faturamento anual ou número de funcionários), excluindo MEIs (Microempreendedores Individuais) devido à informalidade operacional que dificultaria a coleta de dados estruturados.
3. Realização ativa de marketing digital: Presença e atividade em ao menos um canal digital (redes sociais, site institucional, e-commerce, publicidade online, email marketing) nos últimos 12 meses, demonstrando que marketing digital é prática estabelecida ou em construção na empresa.

4. Disponibilidade do gestor: Proprietário, sócio-gestor ou gerente de marketing disponível para participar de entrevista presencial ou remota (60-90 minutos), com autorização para gravação de áudio para fins de transcrição e análise, mediante assinatura de Termo de Consentimento Livre e Esclarecido (TCLE) — requisito ético detalhado na seção 3.6.

CrITÉrios de Diversidade Intencional (Máxima Variação)

Dentro do universo de PMEs elegíveis, a seleção final priorizará máxima variação (*maximum variation sampling*; Patton, 2015) nos seguintes atributos:

1. Porte: Distribuição entre microempresas (< 10 funcionários ou faturamento até R\$ 360 mil/ano), pequenas empresas (10-49 funcionários ou faturamento entre R\$ 360 mil e R\$ 4,8 milhões/ano) e médias empresas (50-249 funcionários ou faturamento entre R\$ 4,8 milhões e R\$ 300 milhões/ano), segundo classificação SEBRAE.
2. Setor de atuação: Representação de pelo menos dois dos três grandes setores — comércio, serviços e indústria —, permitindo análise de variações setoriais conforme Contraste 3 (seção 3.2.3).
3. Estágio de adoção de IA generativa: Diversificação entre:
 - Adotantes ativos: Utilizam regularmente (ao menos semanal) ferramentas de IA generativa no marketing digital há pelo menos 3 meses.
 - Experimentadores: Testaram ferramentas de IA, mas não implementaram uso sistemático.
 - Não-adotantes conscientes: Conhecem a existência das ferramentas, mas optaram por não adotar até o momento.

4. Maturidade digital prévia: Variação entre PMEs com histórico consolidado de práticas digitais (presença em múltiplas plataformas, investimento recorrente em publicidade digital, uso de CRM/automação de marketing) versus PMEs em estágios iniciais de digitalização (presença apenas em uma rede social, gestão informal, sem investimento em mídia paga) — informando se maturidade digital é facilitadora da adoção de IA, conforme literatura sugere (SEBRAE, 2024).

Procedimentos Operacionais de Triagem e Contato

A identificação e triagem de PMEs elegíveis seguirá protocolo sequencial:

Etapa 1 — Mapeamento inicial: Levantamento de PMEs de Capivari-SP através de:

- Cadastros do SEBRAE-SP Regional Piracicaba/Capivari
- Associação Comercial e Industrial de Capivari (ACIC)
- Diretórios públicos (Cadastro Nacional de Empresas da Receita Federal, listas da Prefeitura Municipal)
- Indicações de redes de contato do pesquisador (técnica *snowball sampling* complementar)

Etapa 2 — Contato preliminar: Abordagem via telefone, e-mail ou WhatsApp, apresentando:

- Identificação do pesquisador e vínculo institucional (MUST University)
- Breve descrição dos objetivos da pesquisa
- Convite para participação voluntária
- Garantias de confidencialidade e anonimato (se desejado pela empresa)

Etapa 3 — Aplicação de questionário de triagem: Aos gestores que demonstrarem interesse, será aplicado breve questionário (5-7 perguntas fechadas) via Google Forms ou WhatsApp, coletando:

- Porte da empresa (número de funcionários e/ou faturamento aproximado)
- Setor de atuação (CNAE principal)
- Canais de marketing digital ativos
- Conhecimento sobre ferramentas de IA generativa (sim/não)
- Uso atual de ferramentas de IA no marketing digital (sim, regularmente / sim, experimentei / não)
- Maturidade digital autoavaliada (escala de 1 a 5)

Etapa 4 — Seleção final teoricamente orientada: Com base nas respostas, o pesquisador selecionará 7-8 PMEs que maximizem diversidade conforme critérios de replicação literal e teórica (seções 3.2.2 e 3.2.3). Casos-fronteira (por exemplo, PMEs que responderam "experimentei IA" mas não adotaram sistematicamente) serão priorizados para capturar nuances entre categorias.

Etapa 5 — Agendamento de entrevistas: Contato formal com gestores selecionados para agendamento de entrevista, envio prévio do TCLE e confirmação de disponibilidade para gravação.

Este protocolo assegura transparência (decisões de seleção são documentadas e justificáveis), flexibilidade (permite ajustes se categorias específicas forem sub-representadas no

universo acessível) e rigor ético (respeita autonomia e confidencialidade dos participantes desde o primeiro contato).

3.2.6. Síntese Integradora: Matriz Objetivos-Replicação-Casos

A coerência metodológica de um estudo de caso múltiplo exige articulação explícita entre objetivos de pesquisa, estratégia de replicação e configuração empírica de casos. Esta seção apresenta síntese integradora através de matriz analítica (Quadro X) que demonstra como a estratégia descrita nas seções anteriores operacionaliza os três objetivos específicos do estudo.

Quadro 3: Articulação entre Objetivos Específicos, Lógica de Replicação e Configuração de Casos

Objetivo Específico	Dimensão Investigativa	Tipo de Replicação Necessária	Configuração Mínima de Casos	Contribuição Analítica Esperada
OE1: Identificar práticas de Marketing Digital estabelecidas e como ferramentas de IA estão sendo integradas a essas práticas	Descritiva-Exploratória	Replicação literal (3 casos adotantes similares) + Replicação teórica (2 casos não-adotantes)	Mínimo 5 casos	Mapeamento de práticas convergentes entre adotantes (padrões robustos) e identificação de lacunas/diferenças em não-adotantes (fronteiras de adoção)

OE2: Analisar, sob a perspectiva dos gestores, os impactos percebidos da adoção de IA nas operações, processos decisórios e resultados do Marketing Digital	Perceptiva-Analítica	Replicação literal (3 casos adotantes) + Replicação teórica por porte (micro vs. pequena vs. média)	Mínimo 5 casos	Validação de categorias de impacto através de convergência entre casos similares + identificação de moderadores organizacionais (porte) que amplificam ou atenuam impactos percebidos
OE3: Identificar, à luz do modelo UTAUT, os fatores determinantes na decisão de adoção ou não-adoção de ferramentas de IA para Marketing Digital	Explicativa-Interpretativa	Replicação teórica por estágio de adoção (adotantes vs. não-adotantes) + Replicação teórica por setor e porte	Mínimo 6 casos	Testagem dos construtos UTAUT (Performance Expectancy, Effort Expectancy, Social Influence, Facilitating Conditions) em condições contrastantes, identificando quais fatores são mais salientes em cada contexto e como moderadores organizacionais influenciam decisões
Conjunto Integrado	Compreensão Holística	Replicações literal + teóricas múltiplas	7-8 casos	Resposta abrangente ao problema de pesquisa: como (OE1), com quais impactos percebidos (OE2) e por que (OE3) a IA reconfigura práticas de marketing digital em PMEs de Capivari-SP

Fonte: Elaborado pelo autor (2026).

Nota metodológica: A configuração de 7-8 casos assegura redundância analítica — cada objetivo pode ser respondido por múltiplos casos, fortalecendo a robustez dos achados. Por exemplo, o OE3 (fatores UTAUT) será informado por todos os casos (adotantes e não-adotantes, portes variados, setores distintos), permitindo análise cruzada rica e identificação de padrões multidimensionais.

A matriz demonstra que o desenho metodológico não é arbitrário, mas teoricamente fundamentado e empiricamente viável. Cada tipo de replicação responde a questões analíticas específicas: replicações literais estabelecem padrões-núcleo, replicações teóricas testam limites e moderadores. A convergência de múltiplas fontes de evidência — três casos literais convergindo em práticas similares, contrastados com dois não-adotantes que divergem previsivelmente — fortalece tanto a validade interna (as conclusões sobre cada caso são robustas) quanto a validade externa (os padrões identificados são transferíveis a contextos similares) dos achados (Yin, 2015).

3.2.7. Síntese da Estratégia

A estratégia de replicação aqui estabelecida orienta os próximos passos metodológicos, assegurando coerência estrutural do Capítulo 3. O item 3.3 (Definição da População e Critérios de Seleção) detalhará os procedimentos operacionais de triagem, contato e seleção final das PMEs participantes, expandindo o protocolo delineado na seção 3.2.5. O item 3.4 (Instrumentos e Procedimentos de Coleta de Dados) apresentará o roteiro de entrevistas semiestruturadas, estruturado segundo os construtos do framework conceitual integrado (Capítulo 2, seção 2.5) e alinhado à lógica de replicação — com questões específicas para adotantes versus não-adotantes, por exemplo. O item 3.5 (Procedimentos de Análise de Dados) explicitará como a Análise de

Conteúdo (Bardin, 2016) será aplicada para identificar padrões convergentes (replicações literais) e divergentes (replicações teóricas) nas narrativas dos gestores, conectando dados empíricos aos construtos teóricos. Por fim, o item 3.6 (Aspectos Éticos da Pesquisa) formalizará os protocolos de consentimento, confidencialidade e proteção de dados que assegurarão conformidade com princípios éticos e regulatórios (Resolução CNS 510/2016, LGPD).

3.3 Definição da População e Critérios de Seleção

3.4 Instrumentos e Procedimentos de Coleta de Dados

3.5 Procedimentos de Análise de Dados

3.6 Aspectos Éticos da Pesquisa

4 APRESENTAÇÃO E ANÁLISE DOS RESULTADOS

4.1 Caracterização das Empresas Investigadas

4.2 Análise Temática conforme Objetivos Específicos

4.2.1 Práticas de Marketing Digital e Integração da IA

4.2.2 Impactos Percebidos da Adoção de IA

4.2.3 Fatores Determinantes para Adoção: Análise à Luz do UTAUT

4.3 Síntese dos Achados por Caso

5 DISCUSSÃO DOS RESULTADOS

5.1 Confronto dos Achados com a Literatura

5.2 Implicações Teóricas

5.3 Implicações Práticas e Gerenciais

6 CONCLUSÕES E RECOMENDAÇÕES

6.1 Conclusões em Relação aos Objetivos

6.2 Limitações do Estudo

6.3 Recomendações para Futuras Pesquisas

6.4 Recomendações para Gestores de PMEs

REFERÊNCIAS

- Abdat, T. (2020). Using UTAUT model to predict social media adoption among Indonesian SMEs. *Journal of Socio-Economic and Development*, 1(2), 51–60. <https://doi.org/10.31328/jsed.v1i2.1319>
- Amaral, S. A. (2000). Os 4Ps do composto de marketing na literatura de ciência da informação. *Transinformação*, 12(2), 51-60. <https://doi.org/10.1590/S0103-37862000000200004>
- Amin, A., Gohar, R., & Ali, S. A. (2025). Impact of digital transformation on SME's marketing performance: Role of social media and market turbulence. *Asian Journal of Business and Halal Research*. <https://doi.org/10.1007/s43621-025-01228-3>
- Bardin, L. (2016). Análise de conteúdo (L. A. Reto & A. Pinheiro, Trans.). *Edições 70*. (Obra original publicada em 1977)

- Barney, J. (1991). Firm resources and sustained competitive advantage. *Journal of Management*, 17(1), 99–120. <https://doi.org/10.1177/014920639101700108>
- Beynon, M., Munday, M., & Roche, N. (2021). ICT resources and use: Examining differences in pathways to improved small firm performance. *International Journal of Entrepreneurial Behaviour and Research*, 27(7), 1798-1818. <https://doi.org/10.1108/IJEBr-12-2020-0847>
- Bryman, A. (2012). Social research methods (4^a ed.). Oxford University Press.
- Castanheira, R., Vaz, J., & Cardoso, P. (2022). O marketing digital nas pequenas e médias empresas da indústria têxtil e vestuário portuguesa. *International Journal of Business & Marketing*, 7(2), 4–17.
- Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review*, 96(1), 108-116.
- Davenport, T. H., Guha, A., Grewal, D., & Bressgott, T. (2020). How artificial intelligence will change the future of marketing. *Journal of the Academy of Marketing Science*, 48(1), 24-42. <https://doi.org/10.1007/s11747-019-00696-0>
- Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS Quarterly*, 13(3), 319-340. <https://doi.org/10.2307/249008>
- Gabriel, M., & Kiso, R. (2023). Marketing na era digital: Conceitos, plataformas e estratégias (2^a ed.). Atlas.

- Godin, S. (1999). *Permission marketing: Turning strangers into friends, and friends into customers*. Simon & Schuster.
- Grisson, M. F., Lucchese, G. S., Baggio, D. K., & Trennepohl, D. (2019). Marketing digital: Uso e práticas em pequenas e médias empresas de um município brasileiro de pequeno porte. *Revista Contribuciones a las Ciencias Sociales*.
<https://www.eumed.net/rev/cccss/2019/12/marketing-digital-empresas.html>
- Has, M., & Knežević, D. (2024). Digitalization in small and medium enterprises: A review and research agenda. *Ekonomski Vjesnik*, 37(1), 163-179. <https://doi.org/10.51680/ev.37.1.12>
- Huang, M. H., & Rust, R. T. (2018). Artificial intelligence in service. *Journal of Service Research*, 21(2), 155-172. <https://doi.org/10.1177/1094670517752459>
- Instituto Brasileiro de Geografia e Estatística. (2021). *Demografia das empresas e estatísticas de empreendedorismo*. 2019. IBGE.
<https://biblioteca.ibge.gov.br/visualizacao/livros/liv101796.pdf>
- Järvinen, J., & Taiminen, H. (2016). Harnessing marketing automation for B2B content marketing. *Industrial Marketing Management*, 54, 164-175.
<https://doi.org/10.1016/j.indmarman.2015.07.002>
- Kanezaki, P. D., Oliveira, R. D., & Canella, V. B. (2024). Marketing digital: Contribuições da inteligência artificial na criação de conteúdo estratégico personalizado. *Revista Aracê*, 6(4), 15621-15659. <https://doi.org/10.56238/arev6n4-269>



- Kotler, P., Keller, KL, Chernev, A. (2024). Administração de marketing. (16a ed.) *Bookman*.
<https://plataforma.bvirtual.com.br>
- Kotler, P., Kartajaya, H., & Setiawan, I. (2025). Marketing 6.0: O futuro é imersivo (A. Fontenelle, Trad.; 1ª ed.). Sextante. (Obra original publicada em 2024)
- Nishi, J. M., & Löbler, M. L. (2018, novembro). A (re)construção do modelo UTAUT 2 em contexto brasileiro [Artigo apresentado]. XXI Seminários em Administração (SEMEAD), São Paulo, SP, Brasil.
- Serviço Brasileiro de Apoio às Micro e Pequenas Empresas. (2023). Anuário do trabalho nos pequenos negócios: 2022. *SEBRAE/DIEESE*.
<https://datasebrae.com.br/wp-content/uploads/2023/07/Anuario-do-Trabalho-SEBRAE-DIEESE-2022.pdf>
- Serviço Brasileiro de Apoio às Micro e Pequenas Empresas & Agência Brasileira de Desenvolvimento Industrial. (2023). Mapa da digitalização das MPEs brasileiras 2023.
<https://datasebrae.com.br/maturidade-digital/>
- Serviço Brasileiro de Apoio às Micro e Pequenas Empresas & Agência Brasileira de Desenvolvimento Industrial. (2024). Mapa da digitalização das MPEs brasileiras 2024.
<https://datasebrae.com.br/maturidade-digital/>
- Serviço Brasileiro de Apoio às Micro e Pequenas Empresas & Fundação Getúlio Vargas. (2024). Panorama das micro e pequenas empresas no Brasil.

- Serviço Brasileiro de Apoio às Micro e Pequenas Empresas. (2025). *Transformação digital nos pequenos negócios 2025* (7ª ed.). <https://sebraepr.com.br/impulsiona/pesquisa-tic-2025-transformacao-digital-nos-pequenos-negocios/>
- Sharabati, A. A. A., Al-Haddad, S., Al-Khasawneh, M., Nababteh, N., & Al-Nawaiseh, M. (2024). The impact of digital marketing on the performance of SMEs: An analytical study in light of modern digital transformations. *Malaysian Journal of Social Sciences and Humanities (MJSSH)*, 15(2), 237–251. <https://doi.org/10.47836/mjss.15.2.19>
- Taiminen, H., & Karjaluoto, H. (2015). The usage of digital marketing channels in SMEs. *Journal of Small Business and Enterprise Development*, 22(4), 633-651. <https://doi.org/10.1108/JSBED-05-2013-0073>
- Thaha, A. R., Maulina, E., Muftiadi, R. A., & Alexandri, M. B. (2021). Digital marketing and SMEs: A systematic mapping study. *Library Philosophy and Practice*, 1-21.
- Torres, C. (2009). *A bíblia do marketing digital*. Novatec Editora.
- Venkatesh, V., Morris, M. G., Davis, G. B., & Davis, F. D. (2003). User acceptance of information technology: Toward a unified view. *MIS Quarterly*, 27(3), 425-478. <https://doi.org/10.2307/30036540>
- Venkatesh, V., Thong, J. Y. L., & Xu, X. (2012). Consumer acceptance and use of information technology: Extending the unified theory of acceptance and use of technology. *MIS Quarterly*, 36(1), 157-178. <https://doi.org/10.2307/41410412>

Vial, G. (2019). Understanding digital transformation: A review and a research agenda. *The Journal of Strategic Information Systems*, 28(2), 118–144. <https://doi.org/10.1016/j.jsis.2019.01.003>

GLOSSÁRIO

APÊNDICE